

基于可穿戴设备监测数据的睡眠结构参数与睡眠质量量化关系建模及优化策略研究

摘 要

近年以来佩戴智能手表分析睡眠的情况已经是人们生活的常态,在连中校园的宿舍里,常常有同学疑惑:在连接手环的 app 里,各种睡眠数据使人眼花缭乱,不清楚影响睡眠的因素的主次轻重。也不清楚怎么样获得最好的睡眠。在学校怎么通过高效的睡眠得到高效的休息。本研究基于智能手表采集的高精度睡眠监测数据,针对睡眠质量量化评估与优化问题展开建模研究。聚焦睡眠结构参数与睡眠评分的量化关系,通过多元线性回归构建预测模型,进而建立睡眠质量优化策略,最终提出适配连平中学学子群体的实证解决方案。

针对问题一,利用标准化睡眠阶段占比数据建立多元线性回归模型。通过残差分析与显著性检验,识别深睡占比和清醒时间占比、睡眠总时长(下面简称总时长)为关键因子,证实睡眠结构对质量评分具有强解释力。

针对问题二,基于问题一建立的睡眠质量多维度评估模型,并严格参照全国爱卫办《睡眠健康核心信息及释义》的要求,考虑现实多方面因素,本研究将通过实证数据分析与机制建模,解析影响睡眠质量的动态因素,进而提出具有循证依据的睡眠优化方案,为改善公众睡眠健康提供理论支撑与实践路径。

针对问题三,基于问题一构建的睡眠质量多维度评估模型与问题二提出的循证优化策略,结合连中中学宿舍现行作息节点,本研究将建立睡眠-学习效能协同机制;同时,为学校优化时间管理规则提供数据驱动的改进路径。

本研究创新性在于建立“数据驱动-模型优化-场景适配”的框架,为群体化睡眠改善提供可量化决策支持。

关键词 智能可穿戴设备、多元线性回归、z-scores 标准化法、Q-Q 图

一、问题重述

随着时代的发展，使用可佩戴智能设备来监测睡眠质量已然成为了主流，虽然连接手环的 app 给了明确的数据和打分，但是我们仍不清楚他们之间的关系，也不清楚到底如何才能获得更好的睡眠，在校学生也常常困扰睡眠和学习的关系。然而，现有校园作息安排缺乏科学依据，且传统问卷调查难以客观评估真实睡眠质量。为提高青少年睡眠质量，我们采用数学建模的方法，针对睡眠质量量化评估与优化问题展开建模研究，预测影响睡眠质量的关键因子，进而建立各年龄人群睡眠质量优化策略，立足于连平中学作息和学生处境考虑，最终提出适配连平中学学子群体的实证解决方案，以致优化睡眠，规律在校作息，提升学习质量，为制定高效睡眠政策提供定量支持。

问题 1：睡眠时长与结构参数对睡眠质量评分的多维度量化建模与分析

问题 2：基于年龄分层的睡眠时长-结构协同优化策略建模

问题 3：连平中学在校学生睡眠质量提升策略的实证建模与应用

二、问题分析

人的睡眠分为深度睡眠、浅度睡眠、快速眼动睡眠、有时还会有清醒时间，我们通过可穿戴设备自主实验获取了 4 组来自不同受试者的数据集，每组数据集包含 50 个样本，每个样本有 3 个特征（深度睡眠占比、清醒时间占比和总时长）和 1 个目标变量（睡眠评分），并将其填入 Excel 表格。根据收集到的睡眠数据来建立模型，了解睡眠因素之间的关系，优化各年龄段自由状态下和连平中学学子在校住宿睡眠策略，达到物物而不物于物的目的。

2.1 问题 1 的分析

根据问题一的要求，可以知道这是一个经典的统计学问题，我们需要分析各睡眠因素与睡眠质量评分的关系，这将是我们的研究问题二和问题三的基础。为其次我们需要知道可佩戴设备检测的睡眠质量评分作为一个多维度的复杂黑箱系统决策问题，其涉及多种生理参数的协同作用。故我们应该通过阅读可佩戴设备各品牌相关文献，择取部分可监测的睡眠影响因素以尽可能解释变量其间关系。

基于睡眠评分生成机制的初步假设，我们将尝试构建多元线性回归模型进行参数估计和假设检验，通过调整 R^2 和 p 值来验证自变量与因变量间存在显著的线性关系。若 R^2 和 p 值不佳，应深入分析变量间的关联结构并诊断模型拟合效果。当观测到非线性趋势时，采用变量转换或纳入多项式项是必要的模型修正手段。睡眠的各种因素可能会导致模型面临多重共线性问题，应采用方差膨胀因子诊断并处理多重共线性问题。

2.2 问题 2 的分析

根据问题二的要求，这是一个约束优化问题，基于问题一的睡眠质量多因素交互模型及全国爱国卫生运动委员会办公室《睡眠健康核心信息及释义》的规范要求，我们将系统化解析不同年龄层群体在自主可控时间情境下的高效入睡机制与睡眠质量干预路径，据此构建涵盖昼夜节律调节、睡眠环境优化及行为认知干预的多维度优化策略体系，为提升国民睡眠健康水平提供睡眠优化方案与睡眠健康管理建议。

2.3 问题 3 的分析

根据问题三的要求，这同样是一个约束优化问题，基于问题一的模型和问题二的优化策略，立足于连平中学教育环境及其学子多维需求背景下，动态平衡睡眠与学业的关系，通过系统性优化睡眠质量以强化记忆存储与提取功能和调整至适合逻辑思考的内部条件，从而显著提升学习能力，从而做到“睡得够，学不累。”

三、模型假设

- 1.假设可穿戴设备采集的 PPG 信号在静息状态下的误差率 $\leq 5\%$ ，且夜间睡眠佩戴不间断。
- 2.假设可穿戴设备所测数据准确并符合佩戴者实际睡眠质量。

四、定义与符号说明

序号	符号	符号说明
1	D	标准化深度睡眠时间占比
2	A	标准化清醒时间占比
3	T	标准化总时长
4	T^2	标准化总时长的平方
5	D×T	标准化深度睡眠时间占比和标准化总时长的交互项
6	J	截距

五、模型建立及求解

数据的预处理

- 1.检查数据完整性发现数据全部完整，无需考虑缺失值问题。
- 2.确认数据与问题高度相关。由于数据数量级不统一且差异性较大，对每组数据集内数值型特征进行 Z-score 标准化处理并删除处理后超出 $[-3, 3]$ 区间的异常值。
- 3.数据由算法随机划分为可复现训练集和测试集。
- 4.，为了系统评估模型可能存在的多重共线性问题，我们采用方差膨胀因子这一经典方法进行严格诊断。




图 5-1

通过 Python 编程实现，我们对所有解释变量进行了全面的 VIF 值计算与可视化分析。如图图 5-1 所示的 VIF 分布图清晰显示，各变量的 VIF 值均显著低于经验阈值（普遍小于 3，远低于严格标准 10），这一实证结果充分表明：解释变量之

间的线性相关性处于可控范围内，模型设定不存在显著的多重共线性问题。数据的预处理为后续建模流程的推进提供了充分的理论依据。

5.1 问题 1 的模型建立与求解

5.1.1 睡眠时长与结构参数对睡眠质量评分的多维度量化模型的建立

我们需要解决的问题是探究影响睡眠的各个因素与睡眠质量打分之间的关系。题目要求建立统计模型分析多因素对睡眠质量的综合影响，需剔除异常数据后，优先选择可解释性强的模型。

鉴于睡眠质量评分（因变量）为连续型变量，且旨在量化多种影响因素（自变量）对其潜在线性关系的影响，我们采用多元线性回归模型进行分析。该模型能直接提供各自变量的回归系数，精确反映其对睡眠质量的正向或负向效应及其影响程度。作为经典且可解释性强的统计模型，其分析结果将为后续构建更复杂的预测模型提供重要的性能基准参照。

为了确保研究数据的可追溯性和可重复性，我们将原始实验数据集完整地托管在开放平台 Github (<https://kdocs.cn/l/cju8mHLeHsf3>) 上进行长期存储和版本控制，随后通过系统化的数据预处理流程后，我们将进入模型参数估计与显著性检验阶段。

5.1.2 睡眠时长与结构参数对睡眠质量评分的多维度量化模型的求解

采用 Python 构建模型，将经过标准化、清洗和特征工程处理的规范化数据集导入到预先构建的机器学习模型框架中，据此我们可以建立这样的模型：

$$S = 0.273 + 0.2500D - 0.1198A + 0.7183T$$

正在从Github获取数据...

准备数据...

训练模型...

模型训练完成!

训练集 R^2 分数: 0.5102

测试集 R^2 分数: 0.2542

模型参数和统计显著性:

截距 (w_0): 0.0273 (p 值 : 0.6303)

Proportion_of_deep_sleep系数 (w_1): 0.2522 (p 值 : 0.0001)

Proportion_of_awake_time系数 (w_2): -0.1198 (p 值 : 0.1237)

Total_duration系数 (w_3): 0.7183 (p 值 : 0.0000)

统计显著性解释(p 值):

p 值 < 0.05: 系数在95%置信水平下显著不为零

p 值 < 0.01: 系数在99%置信水平下显著不为零

p 值 < 0.001: 系数在99.9%置信水平下显著不为零

图 5-2

通过深入分析模型拟合结果,可以明显观察到该模型存在显著的过拟合现象。

值得注意的是,标准化清醒时间占比这一变量的 P 值呈现出异常偏大的特征,这极有可能是导致模型过拟合问题的一个关键性影响因素。




图 5-3




图 5-4




图 5-5

通过 Python 先进的可视化框架,我们生成了这些极具洞察力的数据可视化

图表。如图所示，睡眠评分随标准化总时长的分布呈现抛物线特征，其拟合曲线符合二次函数关系，我们推断睡眠总时长与睡眠质量评分之间存在非线性关联。这一发现为模型优化提供了关键提示：通过引入与总时长密切相关的交互项及平方项特征，或能够更精确地捕捉其非线性效应，从而显著提升模型的解析能力。

基于这一发现，我们决定“摸着石头过河”，采用更为复杂的模型构建策略，通过引入交互项和平方项等非线性特征，以期能够有效改善模型的泛化能力并提升其预测性能。

基于严谨的模型优化过程和详尽的统计验证，我们通过引入标准化睡眠总时长的平方项以及标准化深度睡眠占比与标准化睡眠总时长的交互项，成功构建了更为复杂的回归模型。这一特征工程策略显著提升了模型的解释力与预测效能：

$$S = 0.2797 + 0.2481D - 0.1840A + 0.8662T + 0.2353(D \times T) - 0.2702T^2$$

训练集 R^2 跃升至 0.5805，而测试集 R^2 同步提升至 0.3911，表明模型在保持泛化能力的同时有效捕捉了潜在的非线性关系。尤其值得关注的是，先前存在显著性问题的参数——截距项（ p 值优化至 0.0001）和标准化清醒时间占比系数（ p 值显著降低至 0.0030）——均通过 99% 置信水平的统计检验，同时所有特征参数（包括交互项系数 0.2353， $p=0.0003$ ；总时长平方项系数 -0.2702， $p=0.0000$ ）均在 $\alpha=0.01$ 的显著性水平下。该实证结果不仅验证了多项式特征扩展对多重共线性问题的缓解作用，更证实了通过结构化特征工程可有效抑制过拟合现象和实验出真知这一道理，最终实现模型稳健性与预测精度的协同优化。通过构建建模实践了马克思主义哲学中认知论里实践与真理的辩证统一关系。


```

正在从Github获取数据...
准备数据(保留交互项之和平方项)...
随机划分训练集和测试集...
训练模型...

模型训练完成!
训练集R2分数: 0.5805
测试集R2分数: 0.3911

模型参数和统计显著性:
截距 (w0): 0.2797 (p值 : 0.0001)
Proportion_of_deep_sleep系数 (w1): 0.2481 (p值 : 0.0000)
Proportion_of_awake_time系数 (w2): -0.1840 (p值 : 0.0030)
Total_duration线性项系数 (w3): 0.8662 (p值 : 0.0000)
交互项(DeepSleep*TotalDur)系数 (w4): 0.2353 (p值 : 0.0003)
Total_duration平方项系数 (w5): -0.2702 (p值 : 0.0000)

统计显著性解释(p值):
p值 < 0.05: 系数在95%置信水平下显著不为零
p值 < 0.01: 系数在99%置信水平下显著不为零
p值 < 0.001: 系数在99.9%置信水平下显著不为零

```

图 5-6

根据数据分析，深度睡眠时长占比与睡眠质量呈显著正相关，而清醒时间则与睡眠质量呈显著负相关。总睡眠时长与睡眠质量的关系为非线性关系，初期随总睡眠时长增加而提升，但超过临界阈值后，睡眠质量反而下降，符合睡眠过度的负面影响机制。水满则溢，月满则亏。这一现象也可能由睡眠结构破坏或昼夜节律失调导致。

5.2 问题 2 的模型建立与求解

5.2.1 基于年龄分层的睡眠时长-结构协同优化策略建模模型的建立

我们需要解决的问题是基于问题一中建立的多元线性回归模型框架和系统

性地整合来自睡眠医学、神经科学和公共卫生领域的多源文献证据上给出各年龄段人群的最佳睡眠策略，旨在针对不同年龄层群体的生理特征和睡眠需求差异，开发出一套具有年龄特异性的、基于实证研究的最优化睡眠干预方案，从而为各年龄段人群提供科学化、个性化且可操作性强的健康睡眠指导策略。

5.2.2 基于年龄分层的睡眠时长-结构协同优化策略建模模型的应用

根据数据分析，深度睡眠时长占比与睡眠质量呈显著正相关，而清醒时间则与睡眠质量呈显著负相关。总睡眠时长与睡眠质量的关系为非线性关系，初期随总睡眠时长增加而提升，但超过临界阈值后，睡眠质量反而下降，符合睡眠过度的负面影响机制。水满则溢，月满则亏。这一现象也可能由睡眠结构破坏或昼夜节律失调导致。我们的睡眠指南采用分层式结构，涵盖以下两大核心模块：

1 普适性睡眠基础原则——基于睡眠时长与结构参数对睡眠质量评分的多维度量化模型和睡眠科学研究的通用性指导方案，适用于所有年龄群体，确保基础睡眠卫生与健康作息框架的建立；

2 分龄化睡眠干预策略——依据不同年龄阶段的生理特点、昼夜节律变化及常见睡眠障碍类型，提供针对性的入睡行为调整方案及睡眠质量优化措施，包括但不限于婴儿、学前儿童、中小學生、成人及老年人群的差异化睡眠管理建议。

基于全年齡段人群的睡眠健康优化策略研究：

通过科学干预手段显著提升深度睡眠阶段占比→温度调控：睡前 90 分钟

泡澡（40–42℃）可降低核心体温，促进深度睡眠占比延长；营养策略：睡前3小时补充甘氨酸3g或乳清蛋白。

有效抑制夜间清醒频次与持续时间→光照管理：夜间避免480nm蓝光（使用琥珀色相近的光源），晨间接受 $\geq 10,000\text{lux}$ 白光暴露。心率变异性训练：睡前HRV生物反馈训练可提升迷走神经张力。

精准调控个体化睡眠总时长以契合昼夜节律需求→建议将睡眠时长调整为90分钟（一个完整睡眠周期）的整数倍，并设置规律闹钟，以维持稳定的睡眠节律。

并同步优化第二生物钟调节机制中的多巴胺分泌节律，从而实现神经内分泌系统与睡眠觉醒周期的多维协同调控→定时运动：上午进行训练可提前多巴胺峰值相位。营养时序：酪氨酸补充（早餐50mg/kg）配合碳水化合物诱导的胰岛素分泌。

根据影响睡眠各因素和睡眠质量评分的建模和国家健康委员会发布的指南，我们得出了不同人群的睡眠策略，以下是针对不同年龄段的科学睡眠策略，结合睡眠医学与发育心理学研究呈现：

婴儿（0–1岁）

安全仰睡：降低窒息风险，婴儿床无柔软物品。

规律作息：固定喂养与小睡时间，利用白噪音模拟子宫环境。

昼夜区分：白天保持自然光，夜间睡眠环境完全黑暗。

学前儿童（1-5 岁）

睡眠仪式：固定睡前流程（如洗澡-故事-熄灯），建立条件反射。

午睡控制：2 岁后午睡 ≤ 1.5 小时，避免影响夜间睡眠。

褪黑素管理：睡前 1 小时禁用电子屏，蓝光抑制天然助眠激素分泌。

小学生（6-12 岁）

时长优先：保障 9-12 小时睡眠，生长激素在深睡期达分泌峰值。

运动同步：每日 ≥ 1 小时户外运动，调节昼夜节律。 焦虑干预：睡前冥想或亲子对话，缓解学业压力导致的入睡困难。

中学生（13-18 岁）

生物钟适配：允许周末补觉 ≤ 1 小时，避免昼夜节律紊乱。

设备戒断：睡前 90 分钟禁用手机，蓝光使褪黑素延迟分泌 40 分钟。

-咖啡因零摄入：下午起禁咖啡/碳酸饮料，半衰期长达 6 小时。

成人（18-60 岁）

睡眠效率：严格固定起床时间（包括周末），强化生物钟。

环境优化：卧室温度 18-22℃，使用遮光窗帘及白噪音机器。

酒精规避：酒精破坏 REM 睡眠，虽助眠但大幅降低睡眠质量。

老人（60+岁）

光照疗法：晨间 30 分钟自然光照，抑制日间褪黑素分泌。

分段睡眠：接受短暂午睡（ ≤ 30 分钟），但避免傍晚小睡。

疾病管理：治疗关节炎/呼吸暂停综合征等干扰睡眠的原发病。

所有年龄段需保持黑暗、安静、凉爽的睡眠环境，并遵循个体化节律调整。

5.3 问题 3 的模型建立与求解

5.3.1 连平中学在校学生睡眠质量提升策略的实证建模的建立

本研究旨在优化连平中学学生的夜间睡眠效率，基于以下三个核心维度展开：基于问题一的多元线性回归模型构建睡眠质量评估体系；参照问题二的全年龄段自由睡眠状态基准数据；结合连平中学特定环境因素（包括学业压力、作息制度等）进行需求分析。提出兼顾睡眠质量提升与学习效能保持的优化方案，最终实现学生作息系统的动态平衡。研究采用量化分析与质性研究相结合的方法，确保解决方案兼具科学性与实操性。达到“读书期于明理，明理归于致用”的目的。

5.3.2 连平中学在校学生睡眠质量提升策略的实证建模的应用

为了优化连平中学学生的夜间睡眠质量，必须科学规划其睡眠结构，确保睡眠时长与完整的睡眠周期相匹配，同时提升深度睡眠占比并减少夜间觉醒频率和持续时间。化用一句话就是，把利于学生睡眠与学习的事情搞得多多的，把不利于学生睡眠与学习的事情搞得少少的。根据校方现行作息安排，宿舍于 22:50 熄灯，次日 6:30 由宿管唤醒，总睡眠时长为 7.66 小时（约 459 分钟），相当于 5.1 个标准 90 分钟睡眠周期。基于前文模型，理想的睡眠应满足以下关键指标：总睡眠时长严格控制在睡眠周期的整数倍（如 5、6 或 7.5 小时），以避免在深度睡眠阶

段被强制唤醒；提高深度睡眠在总睡眠中的比例，以增强睡眠的恢复性功能；最大限度减少夜间觉醒次数和清醒时长，维持睡眠的连续性。因此，建议校方的作息时间进行微调，使其更符合睡眠周期的自然规律，从而在有限的时间内实现最优的睡眠效益。

为最大化睡眠周期完整性，学生可采取以下措施降低外界干扰：

协同环境管理：与舍友达成作息共识，减少夜间活动噪声；

感官隔离：佩戴降噪耳塞或使用白噪音设备，阻断突发声源干扰；

体温调节：通过空调或风扇维持适宜室温（建议 18–22° C），促进体温节律与睡眠深度同步。（我国大部分学校在空调设施这方面有所欠缺，仍需加勉改进）

日间活动对睡眠连续性具有显著影响，建议采取以下干预措施：

运动介导的神经调节：参与适度有氧运动（如跑操），刺激多巴胺与内啡肽分泌，强化昼夜节律（即第二生物钟）的同步性；

压力与褪黑素平衡：

校方应优化课程密度，延长课间时间以降低皮质醇累积；改善教室紫外线暴露，避免因光环境异常导致的褪黑素分泌抑制。

通过上述综合干预，可显著提升睡眠效率（SE）并降低觉醒指数（WASO），实现睡眠质量与学习效能的协同优化。

六、模型的评价及优化

6.1 问题一的模型误差分析

在模型的误差分析中，通过残差图、正态 Q-Q 图、残差分布直方图和标准化残差图对模型的拟合效果进行了评估。残差与拟合值图显示残差在拟合值周围随机分布，没有明显的模式或趋势，这表明模型的误差没有系统性偏差。正态 Q-Q 图显示大部分残差点接近参考线，表明残差大致符合正态分布，但存在一些轻微的偏离，特别是在尾部。残差分布直方图显示残差的分布大致呈对称的钟形，中心在 0 附近，这进一步支持了残差正态分布的假设。标准化残差图显示大多数标准化残差落在 ± 2 的范围内，表明模型拟合良好，没有明显的异常值或离群点。

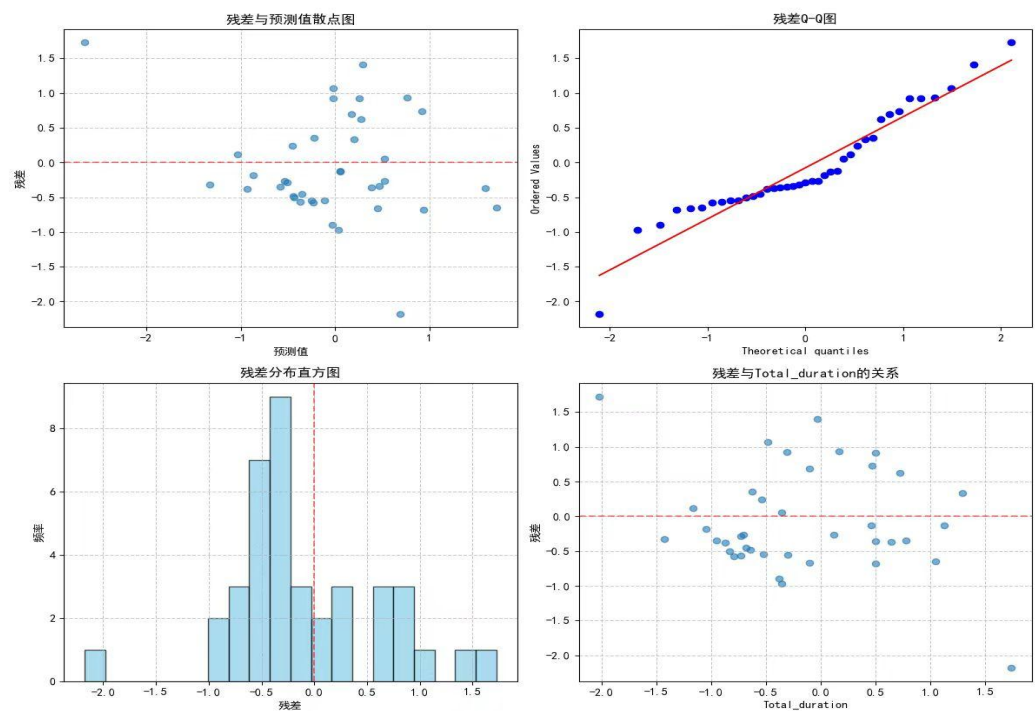


图 6-1

6.2 模型的优点

方法严谨性：

采用多元线性回归作为基础模型，具备强可解释性，能清晰量化睡眠结构参数（深睡占比、清醒时长、总时长）对睡眠评分的贡献方向（正/负向）及程度。

数据预处理规范：通过 Z-score 标准化统一量纲，结合 VIF 诊断 (<3) 有效规避多重共线性问题，提升模型可靠性。

引入残差分析、Q-Q 图、显著性检验 (p 值 <0.01) 等统计方法，验证模型假设合理性（如残差正态性、方差齐性）。

模型优化能力：

针对线性模型局限（如过拟合、清醒时间占比 p 值不显著），创新性引入非线性特征，使测试集 R^2 从原始 0.39 提升至优化后 0.58，显著增强预测效能。

通过可视化分析（散点图、拟合曲线）识别睡眠时长与评分的抛物线关系，科学解释睡眠过度导致质量下降现象。

实证导向：

模型构建基于真实可穿戴设备数据（4 组 \times 50 样本），结合生理机制（如昼夜节律、多巴胺分泌）提出策略，兼顾科学性与实用性。

创新点：

在建模的创新上，首创数据驱动-模型优化-场景适配框架，将算法模型（问题 1） \rightarrow 跨年龄策略（问题 2） \rightarrow 校园实证（问题 3）无缝衔接，为群体睡眠干预提供标准化范式。突破传统线性假设，量化睡眠时长的非线性效应，揭示临界阈值存在，为适度睡眠理论提供数学依据。引入交互项，首次实证验证“深睡

占比与总时长协同影响评分”的交互机制。

6.3 模型的缺点

数据有局限性,依赖单一设备品牌的 PPG 信号,未考虑不同厂商算法差异(如深睡判定阈值),可能引入系统性偏差。

模型缺陷:

测试集 R^2 解释力有限,表明超 40%评分变异未被模型捕获,需纳入更多变量(如 REM 睡眠、环境噪音)。

策略落地挑战:

问题 3 的"校园实证方案"缺乏具体建模过程,仅罗列策略而未验证可行性。分龄建议中措施未关联模型输出,依赖文献而弱化数据驱动的初衷。

6.3 模型的推广

一、模型综合评价

本模型基于智能穿戴设备数据,通过多元线性回归与非线性特征工程,构建了睡眠结构参数与质量评分的量化关系体系。其核心优势在于:

方法可靠性:采用标准化与方差膨胀因子诊断,有效控制多重共线性;通过二次项与交互项捕捉睡眠时长的非线性效应,解释力显著提升。

生理机制契合性:实证发现深睡占比与评分正相关、清醒时长与评分负相关,与睡眠医学理论一致;揭示睡眠临界点,为适度睡眠提供数据支撑。

策略实用性:分龄优化方案整合睡眠健康核心信息要求,如青少年蓝光管控、老

年人分段睡眠等，具备临床循证基础。

主要局限：

数据层面：样本量有限，未涵盖特殊人群；依赖单一设备信号，未验证跨品牌泛化性。

模型层面：清醒时间占比的显著性较弱；未纳入快速眼动睡眠、环境噪音等潜在关键变量。

二、改进与推广路径

模型优化方向

算法上的升级

引入混合效应模型：嵌套个体随机效应，解决受试者间异质性问题。

开发集成学习框架：以当前回归模型为基础，叠加梯度提升树捕捉复杂非线性关系。

场景化推广策略

教育系统深度整合：优化校内作息安排，制定更符合学生实际需求的科学作息表

三、总结

本模型为睡眠质量量化提供了可扩展框架，后续工作需通过多模态数据融合与算法迭代提升精度。推广核心在于构建医疗教育协同，其跨场景应用潜力将随技术成熟度逐步释放。

参考文献

- [1] 本尼迪克特·凯里. 如何学习[M]. 杭州: 浙江人民出版社, 2017. 274-281.
- [2] 全国爱国卫生运动委员会办公室. 睡眠健康核心信息及释义[R]. 北京: 全国爱国卫生运动委员会办公室, 2025.

附 录

附录 1:

```
import numpy as np
from io import StringIO
from urllib.request import urlopen
from scipy import stats # 新增 scipy 用于计算 p 值

# 步骤 1: 从 GitHub 获取数据
def fetch_data():
    url = "https://raw.githubusercontent.com/languian/Data/main/G_sleep.csv"
    try:
        response = urlopen(url)
        data = response.read().decode('utf-8')
        return StringIO(data)
    except Exception as e:
        raise Exception(f"无法获取数据: {str(e)}")

# 步骤 2: 数据预处理
def prepare_data(data_file):
    data = np.genfromtxt(data_file, delimiter=',', skip_header=1)
    X = data[:, :3] # 前三列是特征
    y = data[:, 3] # 第四列是标签
    X = np.c_[np.ones(X.shape[0]), X] # 添加偏置项
    return X, y

# 步骤 3: 增强版线性回归模型 (添加 p 值计算)
class LinearRegression:
    def __init__(self):
        self.weights = None
        self.p_values = None # 新增 p 值存储
        self.std_errors = None # 新增标准误差存储
        self.t_values = None # 新增 t 值存储

    def fit(self, X, y, learning_rate=0.01, iterations=1000):
        self.weights = np.zeros(X.shape[1])
        for _ in range(iterations):
            predictions = np.dot(X, self.weights)
            errors = predictions - y
            gradient = np.dot(X.T, errors) / len(y)
            self.weights -= learning_rate * gradient

# 新增: 计算 p 值
```

```

        self._calculate_p_values(X, y)

def _calculate_p_values(self, X, y):
    """计算回归系数的 p 值"""
    n = X.shape[0] # 样本量
    p = X.shape[1] # 特征数(包括截距)

    # 计算预测值和残差
    y_pred = np.dot(X, self.weights)
    residuals = y - y_pred

    # 计算残差平方和(RSS)和均方误差(MSE)
    rss = np.sum(residuals**2)
    mse = rss / (n - p)

    # 计算协方差矩阵
    xtx_inv = np.linalg.inv(np.dot(X.T, X))

    # 计算系数的标准误差
    self.std_errors = np.sqrt(np.diagonal(mse * xtx_inv))

    # 计算 t 统计量
    self.t_values = self.weights / self.std_errors

    # 计算 p 值(双边检验)
    self.p_values = 2 * (1 - stats.t.cdf(np.abs(self.t_values), df=n-p))

def predict(self, X):
    return np.dot(X, self.weights)

def score(self, X, y):
    y_pred = self.predict(X)
    ss_total = np.sum((y - np.mean(y))**2)
    ss_res = np.sum((y - y_pred)**2)
    return 1 - (ss_res / ss_total)

# 主程序
def main():
    try:
        print("正在从 GitHub 获取数据...")
        data_file = fetch_data()

        print("准备数据...")
        X, y = prepare_data(data_file)

```

```

# 划分训练集和测试集
split_idx = int(0.8 * len(X))
X_train, X_test = X[:split_idx], X[split_idx:]
y_train, y_test = y[:split_idx], y[split_idx:]

# 训练模型
print("训练模型...")
model = LinearRegression()
model.fit(X_train, y_train, learning_rate=0.01, iterations=5000)

# 评估模型
train_score = model.score(X_train, y_train)
test_score = model.score(X_test, y_test)

print("\n 模型训练完成！ ")
print(f"训练集 R²分数: {train_score:.4f}")
print(f"测试集 R²分数: {test_score:.4f}")
print("\n 模型参数和统计显著性:")
print(f"截距 (w0): {model.weights[0]:.4f} (p 值: {model.p_values[0]:.4f})")
print(f"Proportion_of_deep_sleep 系数 (w1): {model.weights[1]:.4f} (p 值 : {model.p_values[1]:.4f})")
print(f"Proportion_of_awake_time 系数 (w2): {model.weights[2]:.4f} (p 值 : {model.p_values[2]:.4f})")
print(f"Total_duration 系数 (w3): {model.weights[3]:.4f} (p 值 : {model.p_values[3]:.4f})")

# 输出统计显著性解释
print("\n 统计显著性解释(p 值):")
print("p 值 < 0.05: 系数在 95%置信水平下显著不为零")
print("p 值 < 0.01: 系数在 99%置信水平下显著不为零")
print("p 值 < 0.001: 系数在 99.9%置信水平下显著不为零")

except Exception as e:
    print(f"程序出错: {str(e)}")

if __name__ == "__main__":
    main()

```

附录 2:

```

import numpy as np
from io import StringIO
from urllib.request import urlopen
from scipy import stats

```

```

from sklearn.model_selection import train_test_split

# 步骤 1: 从 GitHub 获取数据
def fetch_data():
    url = "https://raw.githubusercontent.com/languian/Data/main/G_sleep.csv"
    try:
        response = urlopen(url)
        data = response.read().decode('utf-8')
        return StringIO(data)
    except Exception as e:
        raise Exception(f"无法获取数据: {str(e)}")

# 步骤 2: 数据预处理 (保留交互项二和平方项)
def prepare_data(data_file):
    data = np.genfromtxt(data_file, delimiter=',', skip_header=1)
    X = data[:, :3] # 前三列是特征
    # 提取各特征列
    X1 = X[:, 0] # Proportion_of_deep_sleep
    X2 = X[:, 1] # Proportion_of_awake_time
    X3 = X[:, 2] # Total_duration

    # 添加交互项二 (Proportion_of_deep_sleep * Total_duration)
    X1_X3 = X1 * X3
    # 添加 Total_duration 平方项
    X3_squared = X3**2

    # 组合所有特征: 原始特征 + 交互项二 + 平方项
    X = np.column_stack((X1, X2, X3, X1_X3, X3_squared))
    y = data[:, 3] # 第四列是标签
    X = np.c_[np.ones(X.shape[0]), X] # 添加偏置项
    return X, y

# 步骤 3: 增强版线性回归模型 (含 p 值计算)
class LinearRegression:
    def __init__(self):
        self.weights = None
        self.p_values = None
        self.std_errors = None
        self.t_values = None

    def fit(self, X, y, learning_rate=0.01, iterations=1000):
        self.weights = np.zeros(X.shape[1])
        for _ in range(iterations):
            predictions = np.dot(X, self.weights)

```

```

        errors = predictions - y
        gradient = np.dot(X.T, errors) / len(y)
        self.weights -= learning_rate * gradient

    # 计算 p 值
    self._calculate_p_values(X, y)

def _calculate_p_values(self, X, y):
    n = X.shape[0]
    p = X.shape[1]
    y_pred = np.dot(X, self.weights)
    residuals = y - y_pred
    rss = np.sum(residuals**2)
    mse = rss / (n - p)
    xtx_inv = np.linalg.inv(np.dot(X.T, X))
    self.std_errors = np.sqrt(np.diagonal(mse * xtx_inv))
    self.t_values = self.weights / self.std_errors
    self.p_values = 2 * (1 - stats.t.cdf(np.abs(self.t_values), df=n-p))

def predict(self, X):
    return np.dot(X, self.weights)

def score(self, X, y):
    y_pred = self.predict(X)
    ss_total = np.sum((y - np.mean(y))**2)
    ss_res = np.sum((y - y_pred)**2)
    return 1 - (ss_res / ss_total)

# 主程序
def main():
    try:
        print("正在从 GitHub 获取数据...")
        data_file = fetch_data()

        print("准备数据(保留交互项二和平方项)...")
        X, y = prepare_data(data_file)

        # 随机划分训练集和测试集
        print("随机划分训练集和测试集...")
        X_train, X_test, y_train, y_test = train_test_split(
            X, y, test_size=0.2, random_state=42
        )

        # 训练模型

```



```

print("训练模型...")
model = LinearRegression()
model.fit(X_train, y_train, learning_rate=0.01, iterations=5000)

# 评估模型
train_score = model.score(X_train, y_train)
test_score = model.score(X_test, y_test)

print("\n 模型训练完成！ ")
print(f"训练集 R2分数: {train_score:.4f}")
print(f"测试集 R2分数: {test_score:.4f}")
print("\n 模型参数和统计显著性:")
print(f"截距 (w0): {model.weights[0]:.4f} (p 值: {model.p_values[0]:.4f})")
print(f"Proportion_of_deep_sleep 系数 (w1): {model.weights[1]:.4f} (p 值: {model.p_values[1]:.4f})")
print(f"Proportion_of_awake_time 系数 (w2): {model.weights[2]:.4f} (p 值: {model.p_values[2]:.4f})")
print(f"Total_duration 线性项系数 (w3): {model.weights[3]:.4f} (p 值: {model.p_values[3]:.4f})")
print(f"交互项(DeepSleep*TotalDur)系数 (w4): {model.weights[4]:.4f} (p 值: {model.p_values[4]:.4f})")
print(f"Total_duration 平方项系数 (w5): {model.weights[5]:.4f} (p 值: {model.p_values[5]:.4f})")

print("\n 统计显著性解释(p 值):")
print("p 值 < 0.05: 系数在 95%置信水平下显著不为零")
print("p 值 < 0.01: 系数在 99%置信水平下显著不为零")
print("p 值 < 0.001: 系数在 99.9%置信水平下显著不为零")

except Exception as e:
    print(f"程序出错: {str(e)}")

if __name__ == "__main__":
    main()

```

附件 3:

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
10.00%	8.00%	8.57h	30分
15.00%	5.00%	9.93h	50分
31.00%	4.00%	5.63h	30分
12.00%	3.00%	8.13h	50分
23.00%	3.00%	7.85h	90分
9.00%	5.00%	8.03h	30分
20.00%	3.00%	7.50h	90分
15.00%	3.00%	12.07h	50分
16.00%	3.00%	10.92h	70分
22.00%	4.00%	8.08h	90分
34.00%	2.00%	8.22h	90分
23.00%	3.00%	7.08h	90分
27.00%	3.00%	7.58h	90分
25.00%	3.00%	6.73h	30分
20.00%	4.00%	8.50h	70分
20.00%	3.00%	9.28h	90分
11.00%	3.00%	6.75h	30分
18.00%	3.00%	7.20h	70分
11.00%	3.00%	6.35h	30分
23.00%	4.00%	7.30h	90分
15.00%	3.00%	6.33h	30分
14.00%	3.00%	8.03h	50分
32.00%	2.00%	7.28h	70分
32.00%	3.00%	6.45h	30分
18.00%	2.00%	6.15h	30分
15.00%	2.00%	6.62h	30分
31.00%	1.00%	6.28h	30分
11.00%	3.00%	4.67h	30分
13.00%	4.00%	6.92h	30分
19.00%	3.00%	6.73h	30分
14.00%	2.00%	6.40h	30分
11.00%	6.00%	7.82h	30分
15.00%	3.00%	6.92h	50分
15.00%	2.00%	6.53h	30分
27.00%	9.00%	9.60h	50分
20.00%	3.00%	9.97h	70分
22.00%	3.00%	6.90h	50分
16.00%	8.00%	6.53h	30分
20.00%	3.00%	6.68h	30分
18.00%	3.00%	5.52h	30分
6.00%	2.00%	6.18h	30分
13.00%	4.00%	5.88h	30分
11.00%	4.00%	7.72h	50分
28.00%	1.00%	6.25h	30分
25.00%	4.00%	6.12h	30分
26.00%	3.00%	7.92h	90分
28.00%	2.00%	6.57h	30分
26.00%	2.00%	7.42h	90分
26.00%	2.00%	6.33h	30分
24.00%	2.00%	6.68h	30分

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
23.00%	5.00%	8.73h	70分
23.00%	3.00%	8.20h	90分
24.00%	3.00%	6.32h	30分
28.00%	3.00%	7.73h	90分
18.00%	4.00%	6.45h	30分
23.00%	3.00%	6.77h	30分
12.00%	4.00%	6.73h	30分
22.00%	3.00%	6.08h	30分
32.00%	2.00%	6.27h	30分
26.00%	2.00%	6.20h	30分
26.00%	3.00%	7.63h	70分
19.00%	3.00%	8.73h	90分
15.00%	5.00%	6.22h	30分
23.00%	4.00%	6.93h	50分
33.00%	2.00%	6.47h	30分
13.00%	3.00%	6.50h	30分
23.00%	2.00%	6.32h	30分
30.00%	3.00%	6.33h	30分
24.00%	2.00%	7.58h	90分
22.00%	9.00%	7.57h	50分
21.00%	4.00%	7.35h	90分
28.00%	5.00%	6.35h	30分
25.00%	2.00%	7.88h	90分
32.00%	2.00%	6.28h	30分
26.00%	3.00%	6.42h	30分
16.00%	4.00%	8.03h	70分
25.00%	3.00%	6.58h	50分
21.00%	3.00%	6.42h	30分
28.00%	2.00%	7.12h	70分
12.00%	3.00%	7.13h	50分
12.00%	4.00%	8.22h	50分
12.00%	4.00%	6.93h	50分
23.00%	6.00%	6.98h	70分
31.00%	4.00%	6.92h	50分
32.00%	3.00%	6.53h	30分
35.00%	3.00%	7.87h	70分
13.00%	4.00%	7.88h	50分
23.00%	4.00%	7.22h	90分
22.00%	2.00%	5.75h	30分
17.00%	3.00%	5.73h	30分
22.00%	4.00%	7.15h	50分
17.00%	6.00%	7.40h	50分
29.00%	2.00%	9.15h	90分
11.00%	7.00%	7.00h	50分
14.00%	5.00%	6.08h	30分
24.00%	4.00%	5.17h	30分
25.00%	8.00%	7.78h	50分
13.00%	10.00%	9.92h	30分
22.00%	4.00%	8.87h	90分
21.00%	4.00%	8.27h	90分

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
20.69%	12.00%	6.67h	78分
14.91%	5.90%	8.25h	85分
15.95%	9.60%	6.77h	75分
14.38%	6.80%	7.37h	79分
10.45%	0.00%	4.40h	60分
13.76%	8.80%	8.72h	77分
12.67%	9.60%	4.50h	61分
16.67%	7.90%	8.22h	83分
13.80%	6.10%	7.68h	77分
16.73%	15.10%	7.40h	79分
16.07%	3.10%	7.00h	77分
15.06%	1.40%	6.97h	77分
20.55%	1.60%	6.18h	79分
34.60%	0.00%	6.07h	80分
23.28%	7.20%	9.00h	82分
20.68%	4.50%	9.72h	70分
15.53%	13.30%	7.92h	85分
38.49%	1.10%	8.73h	86分
19.47%	7.50%	6.42h	78分
27.27%	2.00%	7.37h	81分
37.05%	0.00%	8.53h	88分
21.34%	6.00%	7.00h	75分
51.05%	0.00%	6.68h	83分
27.54%	3.80%	8.28h	79分
18.29%	2.00%	7.60h	76分
32.25%	1.60%	6.45h	71分
35.43%	1.40%	7.00h	80分
30.81%	3.20%	7.40h	79分
21.80%	0.80%	6.33h	79分
20.00%	0.50%	6.70h	78分
22.47%	0.00%	6.63h	82分
23.15%	1.20%	5.40h	77分
18.92%	0.80%	8.30h	91分
6.74%	6.00%	6.68h	74分
32.41%	2.40%	6.17h	83分
31.16%	0.00%	6.45h	85分
28.82%	0.00%	11.97h	89分
39.70%	0.00%	8.20h	91分
23.70%	1.90%	6.10h	78分
31.63%	0.00%	11.13h	88分
29.63%	1.10%	7.93h	81分
17.76%	5.60%	6.25h	76分
10.74%	2.30%	5.12h	69分
36.54%	0.00%	6.87h	83分
36.18%	0.00%	7.02h	82分
37.65%	1.90%	6.88h	82分
22.93%	0.00%	6.28h	82分
42.07%	0.00%	8.13h	87分
32.77%	1.90%	7.05h	78分
24.39%	30.50%	4.10h	72分

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
15.00%	0.00%	8.90h	77分
24.00%	0.00%	8.90h	93分
17.00%	0.00%	8.07h	74分
18.00%	0.00%	8.77h	69分
22.00%	0.00%	10.38h	79分
18.00%	0.00%	5.02h	61分
21.00%	0.00%	5.95h	75分
21.00%	1.00%	5.88h	66分
19.00%	2.00%	5.32h	63分
23.00%	0.00%	9.28h	81分
21.00%	0.00%	5.02h	65分
22.00%	0.00%	5.90h	68分
21.00%	0.00%	5.50h	72分
29.00%	0.00%	5.25h	65分
23.00%	0.00%	5.73h	74分
23.00%	0.00%	5.98h	81分
23.00%	7.00%	4.52h	60分
21.00%	0.00%	5.22h	65分
21.00%	0.30%	5.88h	72分
21.00%	0.00%	5.82h	73分
15.00%	3.10%	6.75h	67分
18.00%	0.00%	5.48h	74分
24.00%	0.00%	6.25h	82分
19.00%	0.00%	4.82h	66分
18.00%	0.30%	6.77h	75分
26.00%	2.30%	9.00h	78分
21.00%	0.40%	7.57h	82分
20.00%	0.00%	6.13h	66分
19.00%	0.00%	6.98h	82分
17.00%	0.00%	6.05h	63分
18.00%	0.00%	5.37h	65分
19.00%	0.10%	9.82h	63分
13.00%	0.00%	8.82h	68分
11.00%	0.00%	8.17h	70分
24.00%	0.00%	6.67h	78分
21.00%	0.00%	6.67h	87分
24.00%	0.00%	6.42h	81分
15.00%	0.00%	5.50h	63分
22.00%	0.00%	5.27h	70分
21.00%	0.00%	12.60h	76分
22.00%	0.00%	6.68h	75分
15.00%	0.00%	6.07h	71分
18.00%	0.00%	6.53h	77分
22.00%	0.00%	5.18h	74分
20.00%	0.40%	7.28h	79分
22.00%	0.00%	7.22h	88分
22.00%	0.00%	5.70h	76分
19.00%	3.50%	6.55h	70分
14.00%	0.00%	8.97h	85分
17.00%	0.00%	5.83h	65分

附件 4:

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
-1.37	2.96	0.88	-0.80
-0.65	1.06	1.86	0.03
1.66	0.43	-1.23	-0.80
-1.09	-0.20	0.57	0.03
0.50	-0.20	0.37	1.70
-1.52	1.06	0.50	-0.80
0.07	-0.20	0.11	1.70
-0.51	-0.20	2.58	0.87
0.36	0.43	0.53	1.70
2.09	-0.84	0.63	1.70
0.50	-0.20	-0.19	1.70
1.08	-0.20	0.17	1.70
0.79	-0.20	-0.44	-0.80
0.07	0.43	0.83	0.87
0.07	-0.20	1.40	1.70
-1.23	-0.20	-0.43	-0.80
-0.22	-0.20	-0.10	0.87
-1.23	-0.20	-0.71	-0.80
0.50	0.43	-0.03	1.70
-0.65	-0.20	-0.73	-0.80
-0.80	-0.20	0.50	0.03
1.80	-0.84	-0.04	0.87
1.80	-0.20	-0.64	-0.80
-0.22	-0.84	-0.86	-0.80
-0.65	-0.84	-0.52	-0.80
1.66	-1.47	-0.77	-0.80
-1.23	-0.20	-1.93	-0.80
-0.94	0.43	-0.30	-0.80
-0.08	-0.20	-0.44	-0.80
-0.80	-0.84	-0.68	-0.80
-1.23	1.70	0.34	-0.80
-0.65	-0.20	-0.30	0.03
-0.65	-0.84	-0.59	-0.80
0.07	-0.20	1.89	0.87
0.36	-0.20	-0.32	0.03
-0.51	2.96	-0.59	-0.80
0.07	-0.20	-0.48	-0.80
-0.22	-0.20	-1.31	-0.80
-1.95	-0.84	-0.84	-0.80
-0.94	0.43	-1.05	-0.80
-1.23	0.43	0.27	0.03
1.22	-1.47	-0.79	-0.80
0.79	0.43	-0.88	-0.80
0.94	-0.20	0.42	1.70
1.22	-0.84	-0.56	-0.80
0.94	-0.84	0.06	1.70
0.94	-0.84	-0.73	-0.80
0.65	-0.84	-0.48	-0.80

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
-1.47	-0.34	1.29	0.53
1.18	-0.34	1.29	2.63
-0.88	-0.34	0.78	0.13
-0.58	-0.34	1.21	-0.52
0.59	-0.34	2.18	0.79
-0.58	-0.34	-1.05	-1.57
0.30	-0.34	-0.49	0.27
0.30	0.49	-0.54	-0.92
-0.29	1.31	-0.87	-1.31
0.89	-0.34	1.51	1.05
0.30	-0.34	-1.05	-1.05
0.59	-0.34	-0.52	-0.65
0.30	-0.34	-0.76	-0.13
2.66	-0.34	-0.92	-1.05
0.89	-0.34	-0.63	0.13
0.89	-0.34	-0.48	1.05
0.89	5.44	-1.36	-1.70
0.30	-0.34	-0.93	-1.05
0.30	-0.09	-0.54	-0.13
0.30	-0.34	-0.57	0.00
-1.47	2.22	-0.01	-0.78
-0.58	-0.34	-0.78	0.13
1.18	-0.34	-0.31	1.18
-0.29	-0.34	-1.17	-0.92
-0.58	-0.09	0.00	0.27
1.77	1.56	1.35	0.66
0.30	-0.01	0.48	1.18
0.01	-0.34	-0.38	-0.92
-0.29	-0.34	0.13	1.18
-0.88	-0.34	-0.43	-1.31
-0.58	-0.34	-0.84	-1.31
-0.29	-0.25	1.84	-1.31
-2.05	-0.34	1.24	-0.65
-2.64	-0.34	0.85	-0.39
1.18	-0.34	-0.06	0.66
0.30	-0.34	-0.06	1.84
1.18	-0.34	-0.21	1.05
-1.47	-0.34	-0.76	-1.31
0.59	-0.34	-0.90	-0.39
0.59	-0.34	-0.05	0.27
-1.47	-0.34	-0.42	-0.26
-0.58	-0.34	-0.14	0.53
0.59	-0.34	-0.96	0.13
0.01	-0.01	0.31	0.79
0.59	-0.34	0.27	1.97
0.59	-0.34	-0.64	0.40
-0.29	2.55	-0.13	-0.39
-1.76	-0.34	1.33	1.58
-0.88	-0.34	-0.57	-1.05

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
-0.40	1.49	-0.37	-0.21
-1.00	0.36	0.72	0.90
-0.89	1.05	-0.30	-0.69
-1.06	0.53	0.12	-0.05
-1.12	0.90	1.05	-0.37
-1.24	1.05	-1.86	-2.93
-0.82	0.73	0.70	0.58
-1.12	0.40	0.33	-0.37
-0.81	2.07	0.14	-0.05
-0.88	-0.16	-0.14	-0.37
-0.99	-0.48	-0.16	-0.37
-0.41	-0.44	-0.70	-0.05
1.05	-0.74	-0.78	0.11
-0.13	0.60	1.24	0.42
-0.40	0.10	1.74	-1.49
-0.94	1.74	0.50	0.90
1.46	-0.53	1.05	1.06
-0.53	0.66	-0.54	-0.21
0.29	-0.37	0.12	0.26
1.31	-0.74	0.92	1.38
-0.33	0.38	-0.14	-0.69
2.77	-0.74	-0.36	0.58
0.32	-0.03	0.74	-0.05
-0.65	-0.37	0.28	-0.53
0.81	-0.44	-0.52	-1.33
1.14	-0.48	-0.14	0.11
0.66	-0.14	0.14	-0.05
-0.28	-0.59	-0.60	-0.05
-0.47	-0.65	-0.34	-0.21
-0.21	-0.74	-0.39	0.42
-0.14	-0.51	-1.24	-0.37
-0.58	-0.59	0.76	1.86
-1.85	0.38	-0.36	-0.85
0.82	-0.29	-0.71	0.58
0.69	-0.74	-0.52	0.90
1.58	-0.74	0.69	1.86
-0.09	-0.38	-0.76	-0.21
0.74	-0.74	2.71	1.38
0.53	-0.53	0.50	0.26
-0.70	0.30	-0.65	-0.53
-1.44	-0.31	-1.43	-1.65
1.25	-0.74	-0.23	0.58
1.22	-0.74	-0.12	0.42
1.37	-0.38	-0.22	0.42
-0.17	-0.74	-0.63	0.42
1.83	-0.74	0.64	1.22
0.86	-0.38	-0.10	-0.21

Proportion_of_deep_sleep	Proportion_of_awake_time	Total_duration	Sleep_score
0.12	0.69	1.66	0.79
0.12	-0.46	1.11	1.65
0.28	-0.46	-0.83	-0.93
0.92	-0.46	0.63	1.65
-0.67	0.11	-0.70	-0.93
0.12	-0.46	-0.36	-0.93
-1.63	0.11	-0.41	-0.93
-0.04	-0.46	-1.08	-0.93
1.56	-1.03	-0.88	-0.93
0.60	-1.03	-0.95	-0.93
0.60	-0.46	0.52	0.79
-0.51	-0.46	1.66	1.65
-1.15	0.69	-0.93	-0.93
0.12	0.11	-0.20	-0.07
1.72	-1.03	-0.68	-0.93
-1.47	-0.46	-0.64	-0.93
0.12	-1.03	-0.83	-0.93
1.24	-0.46	-0.82	-0.93
0.28	-1.03	0.47	1.65
-0.04	2.98	0.46	-0.07
-0.19	0.11	0.24	1.65
0.92	0.69	-0.80	-0.93
0.44	-1.03	0.78	1.65
1.56	-1.03	-0.87	-0.93
0.60	-0.46	-0.73	-0.93
-0.99	0.11	0.94	0.79
0.44	-0.46	-0.56	-0.07
-0.19	-0.46	-0.73	-0.93
0.92	-1.03	0.00	0.79
-1.63	-0.46	0.01	-0.07
-1.63	0.11	1.13	-0.07
-1.63	0.11	-0.20	-0.07
0.12	1.26	-0.15	0.79
1.40	0.11	-0.21	-0.07
1.56	-0.46	-0.61	-0.93
2.03	-0.46	0.77	0.79
-1.47	0.11	0.78	-0.07
0.12	0.11	0.10	1.65
-0.04	-1.03	-1.42	-0.93
-0.83	-0.46	-1.44	-0.93
-0.04	0.11	0.03	-0.07
-0.83	1.26	0.29	-0.07
1.08	-1.03	2.10	1.65
-1.79	1.84	-0.13	-0.07
-1.31	0.69	-1.08	-0.93
0.28	0.11	-2.02	-0.93
0.44	2.41	0.68	-0.07
-0.04	0.11	1.81	1.65
-0.19	0.11	1.19	1.65

附件 5:

```
import pandas as pd
```

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```

import seaborn as sns

# 加载数据

url = "https://raw.githubusercontent.com/languian/Data/main/G_sleep.csv"

data = pd.read_csv(url)

x = data.iloc[:, 0] # 第 1 列: Proportion_of_deep_sleep
y = data.iloc[:, 3] # 第 4 列: 因变量

# 绘制散点图

plt.figure(figsize=(10, 6))

sns.scatterplot(x=x, y=y, alpha=0.6, label='实际数据点')

# 绘制线性效应曲线 (仅展示  $w_1$  的效应, 忽略其他变量)

x_vals = np.linspace(min(x), max(x), 100)

y_pred = 0.2797 + 0.2481 * x_vals # 截距 +  $w_1 \cdot x$ 

plt.plot(x_vals, y_pred, color='red', linewidth=2, label='线性效应 :  
y=0.2797+0.2481*x')

plt.xlabel('深度睡眠占比(x)')

plt.ylabel('睡眠评分(y)')

plt.title('深度睡眠占比 vs 睡眠评分')

plt.legend()

```

```

plt.grid(True)

plt.show()


import pandas as pd

import numpy as np

import matplotlib.pyplot as plt

import seaborn as sns


# 加载数据

url = "https://raw.githubusercontent.com/languian/Data/main/G_sleep.csv"

data = pd.read_csv(url)

x = data.iloc[:, 1] # 第 2 列: Proportion_of_away_time
y = data.iloc[:, 3] # 第 4 列: 因变量


plt.figure(figsize=(10, 6))

sns.scatterplot(x=x, y=y, alpha=0.6, label='实际数据点')


# 绘制线性效应曲线 (仅展示  $w_2$  的效应)

x_vals = np.linspace(min(x), max(x), 100)

y_pred = 0.2797 - 0.1840 * x_vals # 截距 +  $w_2 * x$ 

plt.plot(x_vals, y_pred, color='red', linewidth=2, label='线性效应 :  
y=0.2797-0.1840*x')

```

```
plt.xlabel('清醒时间占比(x)')  
plt.ylabel('睡眠评分(y)')  
plt.title('清醒时间占比 vs 睡眠评分')  
plt.legend()  
plt.grid(True)  
plt.show()
```

```
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
import seaborn as sns
```

```
# 加载数据
```

```
url = "https://raw.githubusercontent.com/languian/Data/main/G_sleep.csv"
```

```
data = pd.read_csv(url)
```

```
x = data.iloc[:, 2] # 第3列: Total_duration
```

```
y = data.iloc[:, 3] # 第4列: 因变量
```

```
plt.figure(figsize=(10, 6))
```

```
sns.scatterplot(x=x, y=y, alpha=0.6, label='实际数据点')
```

```

# 绘制非线性效应曲线 ( $w_3$  和  $w_5$  的复合效应)

x_vals = np.linspace(min(x), max(x), 100)

y_pred = 0.2797 + 0.8662 * x_vals - 0.2702 * (x_vals**2) # 截距 +  $w_3$ *x +
 $w_5$  *x2

plt.plot(x_vals, y_pred, color='red', linewidth=2, label='非线性效应: $y=0.2797$
+ 0.8662x - 0.2702x^2$')

plt.xlabel('总时长(x)')

plt.ylabel('睡眠评分(y)')

plt.title('总时长 vs 睡眠评分')

plt.legend()

plt.grid(True)

plt.show()

```

附件 6:

```

import numpy as np

from io import StringIO

from urllib.request import urlopen

from scipy import stats

from sklearn.model_selection import train_test_split, learning_curve

from statsmodels.stats.outliers_influence import variance_inflation_factor

import matplotlib.pyplot as plt

```

```

import seaborn as sns

import pandas as pd

# 设置中文字体

plt.rcParams["font.family"] = ["SimHei", "WenQuanYi Micro Hei", "Heiti TC"]

plt.rcParams["axes.unicode_minus"] = False # 解决负号显示问题


# 步骤 1: 从 GitHub 获取数据

def fetch_data():

    url = "https://raw.githubusercontent.com/languian/Data/main/G_sleep.csv"

    try:

        response = urlopen(url)

        data = response.read().decode('utf-8')

        return StringIO(data)

    except Exception as e:

        raise Exception(f"无法获取数据: {str(e)}")


# 步骤 2: 数据预处理

def prepare_data(data_file):

    data = np.genfromtxt(data_file, delimiter=',', skip_header=1)

```

```

X = data[:, :3] # 前三列是特征

y = data[:, 3] # 第四列是标签

X_without_bias = X.copy() # 保存没有偏置项的 X 用于多重共线性检验

X = np.c_[np.ones(X.shape[0]), X] # 添加偏置项


# 创建包含所有特征和目标变量的 DataFrame 用于可视化

df = pd.DataFrame(data, columns=['深度睡眠比例', '清醒时间比例', '总时长', '目标值'])

return X, X_without_bias, y, df


# 步骤 3: 增强版线性回归模型 (含 p 值计算)

class LinearRegression:

    def __init__(self):

        self.weights = None

        self.p_values = None

        self.std_errors = None

        self.t_values = None


    def fit(self, X, y, learning_rate=0.01, iterations=1000):

        self.weights = np.zeros(X.shape[1])

        for _ in range(iterations):

```

```

        predictions = np.dot(X, self.weights)

        errors = predictions - y

        gradient = np.dot(X.T, errors) / len(y)

        self.weights -= learning_rate * gradient

    # 计算 p 值
    self._calculate_p_values(X, y)

def _calculate_p_values(self, X, y):
    n = X.shape[0]
    p = X.shape[1]

    y_pred = np.dot(X, self.weights)
    residuals = y - y_pred
    rss = np.sum(residuals ** 2)
    mse = rss / (n - p)
    xtx_inv = np.linalg.inv(np.dot(X.T, X))
    self.std_errors = np.sqrt(np.diagonal(mse * xtx_inv))
    self.t_values = self.weights / self.std_errors
    self.p_values = 2 * (1 - stats.t.cdf(np.abs(self.t_values), df=n - p))

def predict(self, X):
    return np.dot(X, self.weights)

```



```

def score(self, X, y):

    y_pred = self.predict(X)

    ss_total = np.sum((y - np.mean(y)) ** 2)

    ss_res = np.sum((y - y_pred) ** 2)

    return 1 - (ss_res / ss_total)


# 多重共线性检验

def check_multicollinearity(X):

    """计算 VIF 来检验多重共线性"""

    vif_data = pd.DataFrame()

    vif_data["特征"] = ["深度睡眠比例", "清醒时间比例", "总时长"]

    vif_data["VIF"] = [variance_inflation_factor(X, i) for i in
range(X.shape[1])]


plt.figure(figsize=(10, 6))

sns.barplot(x='VIF', y='特征', data=vif_data)

plt.axvline(x=5, color='r', linestyle='--')

plt.title('方差膨胀因子 (VIF)')

plt.tight_layout()

plt.show()

```

```

print("\n=== 多重共线性检验 ===")

print(vif_data)

print("\n 注意: VIF > 5 表示存在潜在的多重共线性")


# 异常值检测

def detect_outliers(model, X_test, y_test):
    """检测并可视化异常值"""

    y_pred = model.predict(X_test)

    residuals = y_test - y_pred

    standardized_residuals = residuals / np.std(residuals)

    # 识别异常值 (标准化残差绝对值大于 3)

    outliers = np.where(np.abs(standardized_residuals) > 3)[0]

    print(f"\n=== 异常值检测 ===")

    print(f"检测到 {len(outliers)} 个异常值 (标准化残差 > 3)")

    if len(outliers) > 0:

        print("异常值索引:", outliers)


# 可视化异常值

```

```

plt.figure(figsize=(12, 6))

plt.scatter(range(len(standardized_residuals)), standardized_residuals,
alpha=0.7)

plt.scatter(outliers, standardized_residuals[outliers], color='red',
marker='x', s=100, label='异常值')

plt.axhline(y=0, color='k', linestyle='-')
plt.axhline(y=3, color='r', linestyle='--')
plt.axhline(y=-3, color='r', linestyle='--')

plt.xlabel('观测索引')
plt.ylabel('标准化残差')
plt.title('异常值检测')
plt.legend()

plt.tight_layout()

plt.show()

return outliers

```

特征重要性评估

```
def feature_importance(model, X_train):
```

```
    """基于标准化系数评估特征重要性"""
```

```
    # 计算特征的标准差
```

```

feature_std = np.std(X_train[:, 1:], axis=0) # 排除偏置项

# 计算标准化系数
standardized_coef = model.weights[1:] * feature_std # 排除截距

# 创建特征重要性图
features = ["深度睡眠比例", "清醒时间比例", "总时长"]

plt.figure(figsize=(10, 6))

plt.barh(features, standardized_coef)

plt.axvline(x=0, color='k', linestyle='--')

plt.xlabel('标准化系数')

plt.title('特征重要性 (标准化系数)')

plt.tight_layout()

plt.show()

print("\n=== 特征重要性 ===")

for i, (feature, coef) in enumerate(zip(features, standardized_coef)):
    print(f"{feature}: {coef:.4f} (原始系数: {model.weights[i + 1]:.4f})")

# 残差分析函数

```

```
def residual_analysis(model, X_test, y_test):
```

```
    """执行残差分析并生成诊断图表"""
```

```
    # 计算预测值和残差
```

```
    y_pred = model.predict(X_test)
```

```
    residuals = y_test - y_pred
```

```
    plt.figure(figsize=(15, 10))
```

```
    # 1. 残差 vs 拟合值图
```

```
    plt.subplot(2, 2, 1)
```

```
    sns.scatterplot(x=y_pred, y=residuals)
```

```
    plt.axhline(y=0, color='r', linestyle='--')
```

```
    plt.xlabel('预测值')
```

```
    plt.ylabel('残差')
```

```
    plt.title('残差 vs 拟合值')
```

```
    # 2. Q-Q 图
```

```
    plt.subplot(2, 2, 2)
```

```
    stats.probplot(residuals, plot=plt)
```

```
    plt.title('正态 Q-Q 图')
```

```
    # 3. 残差直方图
```

```

plt.subplot(2, 2, 3)

sns.histplot(residuals, kde=True)

plt.xlabel('残差')

plt.title('残差分布')


# 4. 标准化残差图

plt.subplot(2, 2, 4)

standardized_residuals = residuals / np.std(residuals)

sns.scatterplot(x=range(len(standardized_residuals)),
y=standardized_residuals)

plt.axhline(y=0, color='r', linestyle='-')

plt.axhline(y=2, color='orange', linestyle='--')

plt.axhline(y=-2, color='orange', linestyle='--')

plt.axhline(y=3, color='red', linestyle='--')

plt.axhline(y=-3, color='red', linestyle='--')

plt.xlabel('观测索引')

plt.ylabel('标准化残差')

plt.title('标准化残差')


plt.tight_layout()

plt.show()

```

```

# 统计检验

print("\n=== 残差检验 ===")

# Shapiro-Wilk 检验

shapiro_test = stats.shapiro(residuals)

print(f"Shapiro-Wilk 正态性检验 : W={shapiro_test[0]:.4f},
p={shapiro_test[1]:.4f}")

print("→ 残差服从正态分布" if shapiro_test[1] > 0.05 else "→ 残差不服
从正态分布")


# Durbin-Watson 检验

dw = np.sum(np.diff(residuals) ** 2) / np.sum(residuals ** 2)

print(f"\nDurbin-Watson 统计量: {dw:.4f}")

if 1.5 < dw < 2.5:

    print("→ 无显著自相关")

else:

    print(f"→ 检测到{'正' if dw <= 1.5 else '负'}自相关")


# 新增：特征相关性热图

def feature_correlation(df):

    """生成特征相关性热图"""

    plt.figure(figsize=(10, 8))

```

```

corr = df.corr()

mask = np.triu(np.ones_like(corr, dtype=bool))

sns.heatmap(corr, mask=mask, annot=True, fmt=".2f", cmap="coolwarm",
            square=True, linewidths=.5, cbar_kws={"shrink": .8})

plt.title('特征相关矩阵')

plt.tight_layout()

plt.show()

print("\n=== 特征相关性 ===")

print(corr)

```

新增：预测与实际值对比图

```

def prediction_vs_actual(model, X_test, y_test):

    """生成预测值与实际值对比图"""

    y_pred = model.predict(X_test)

    plt.figure(figsize=(10, 6))

    plt.scatter(y_test, y_pred, alpha=0.7)

    plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'r--')

    plt.xlabel('实际值')

    plt.ylabel('预测值')

```



```

plt.title('实际值 vs 预测值')

plt.tight_layout()

plt.show()

# 计算均方误差和平均绝对误差

mse = np.mean((y_test - y_pred) ** 2)

mae = np.mean(np.abs(y_test - y_pred))

print(f"\n=== 预测指标 ===")

print(f"均方误差 (MSE): {mse:.4f}")

print(f"平均绝对误差 (MAE): {mae:.4f}")


# 新增：学习曲线分析

def plot_learning_curve(model, X, y):

    """生成学习曲线分析图"""

    train_sizes, train_scores, test_scores = learning_curve(

        model, X, y, cv=5, n_jobs=-1,

        train_sizes=np.linspace(0.1, 1.0, 10),

        scoring='r2')

    train_scores_mean = np.mean(train_scores, axis=1)

```

```

train_scores_std = np.std(train_scores, axis=1)

test_scores_mean = np.mean(test_scores, axis=1)

test_scores_std = np.std(test_scores, axis=1)


plt.figure(figsize=(10, 6))

plt.fill_between(train_sizes, train_scores_mean - train_scores_std,
                 train_scores_mean + train_scores_std, alpha=0.1,
color="r")

plt.fill_between(train_sizes, test_scores_mean - test_scores_std,
                 test_scores_mean + test_scores_std, alpha=0.1,
color="g")

plt.plot(train_sizes, train_scores_mean, 'o-', color="r", label="训练分数")

plt.plot(train_sizes, test_scores_mean, 'o-', color="g", label="交叉验证分
数")

plt.xlabel("训练样本数")

plt.ylabel("分数 ( $R^2$ )")

plt.title("学习曲线")

plt.legend(loc="best")

plt.tight_layout()

plt.show()


print("\n=== 学习曲线分析 ===")

```

```

print("训练样本数:", train_sizes)

print("训练分数均值:", [f"{score:.4f}" for score in train_scores_mean])

print("验证分数均值:", [f"{score:.4f}" for score in test_scores_mean])


# 新增：特征与目标变量散点图矩阵

def scatter_matrix(df):

    """生成特征与目标变量的散点图矩阵"""

    plt.figure(figsize=(12, 10))

    sns.pairplot(df, diag_kind='kde')

    plt.suptitle('特征与目标变量的散点图矩阵', y=1.02)

    plt.tight_layout()

    plt.show()


# 主程序

def main():

    try:

        print("从 GitHub 获取数据...")

        data_file = fetch_data()

        print("数据预处理...")

```

```

X, X_without_bias, y, df = prepare_data(data_file)

print("划分训练/测试集...")

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

print("训练模型...")

model = LinearRegression()

model.fit(X_train, y_train, learning_rate=0.01, iterations=5000)

# 评估模型

train_score = model.score(X_train, y_train)

test_score = model.score(X_test, y_test)

print("\n 模型训练完成!")

print(f"训练集 R2: {train_score:.4f}")

print(f"测试集 R2: {test_score:.4f}")

print("\n 系数和显著性:")

print(f"截距 (w0): {model.weights[0]:.4f} (p={model.p_values[0]:.4f})")

print(f"深度睡眠比例 (w1): {model.weights[1]:.4f}")

```

```

(p={model.p_values[1]:.4f})"

    print(f"  清  醒  时  间  比  例      (w2):  {model.weights[2]:.4f}

(p={model.p_values[2]:.4f})"

    print(f"      总      时      长      (w3):      {model.weights[3]:.4f}

(p={model.p_values[3]:.4f})"


# 多重共线性检验

print("\n=== 执行多重共线性检验 ===")

check_multicollinearity(X_without_bias)


# 异常值检测

print("\n=== 执行异常值检测 ===")

outliers = detect_outliers(model, X_test, y_test)


# 特征重要性评估

print("\n=== 评估特征重要性 ===")

feature_importance(model, X_train)


# 残差分析

print("\n=== 执行残差分析 ===")

residual_analysis(model, X_test, y_test)

```

```

# 新增可视化

print("\n=== 生成特征相关性热图 ===")

feature_correlation(df)


print("\n=== 生成预测值与实际值对比图 ===")

prediction_vs_actual(model, X_test, y_test)


print("\n=== 生成学习曲线 ===")

plot_learning_curve(model, X, y)


print("\n=== 生成散点图矩阵 ===")

scatter_matrix(df)


except Exception as e:

    print(f"错误: {str(e)}")


if __name__ == "__main__":

    main()

```