

系统仿真学报
Journal of System Simulation
ISSN 1004-731X, CN 11-3092/V

《系统仿真学报》网络首发论文

题目：基于神经网络的无人车动力学建模方法
作者：王军，刘敏，张啸川，丁一珊，冯居辉，庄晔
网络首发日期：2025-07-08
引用格式：王军，刘敏，张啸川，丁一珊，冯居辉，庄晔. 基于神经网络的无人车动力学建模方法[J/OL]. 系统仿真学报.
<https://link.cnki.net/urlid/11.3092.V.20250707.1631.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于神经网络的无人车动力学建模方法

王军¹, 刘敏^{1,*}, 张啸川¹, 丁一珊², 冯居辉³, 庄晔³

(1.智能博弈与决策实验室(军事智能研究院),北京市,100001;2.国防科技创新研究院,北京市,100071;3.吉林大学,汽车底盘集成与仿生全国重点实验室,吉林省 长春市 130021)

摘要: 面向复杂战场仿真条件下多无人车协作细粒度并行仿真需求,针对无人车在复杂陆域环境下轮胎与软路面之间动力学特性试验数据获取成本高、数值计算速度慢的问题,提出一种面向复杂陆域环境的基于神经网络的无人车动力学模型建模方法,实现了基于深度学习与物理知识嵌入的非线性高精度无人车动力学仿真。该方法首先利用轮胎-路面接触离散元(DEM)模拟及试验数据构建轮-地接触动力学模型,生成陆域环境不同材质下(泥地、沙地)轮胎接触力试验数据集,应用神经网络对该数据集进行回归学习,构建了非线性神经网络轮胎模型;然后,基于非线性神经网络轮胎模型搭建了无人车三自由度动力学模型,并基于该模型仿真生成了具有物理意义及边界的数据集,应用该数据集实现了无人车动力学解算残差神经网络的学习训练。最后,对基于神经网络的无人车动力学模型进行了训练效果和轨迹跟踪控制效果验证,试验结果表明,基于神经网络构建的无人车动力学解算模型可以实现无人车动力学高精度和高效率仿真,满足模拟仿真环境下大规模无人车高精度快速解算需求,并能够更好的实现细粒度无人车轨迹跟踪控制。

关键词: 神经网络;深度学习;汽车动力学建模;接触离散元建模;轮胎摩擦建模

中图分类号: TP18; U461.1 文献标志码: A

A neural network-based approach to modelling unmanned vehicle dynamics

Wang Jun¹, Liu Min^{1,*}, Zhang Xiaochuan¹, Ding Yishan², Feng Juhui³, Zhuang Ye³

(1. Intelligent Game and Decision Lab(Military Intelligence Institute), Beijing 100001, China; 2. Defense Innovation Institute, Beijing 100071, China; 3. Jilin University, National Key Laboratory of Automotive Chassis Integration and Bionics, Changchun 130021, China)

Abstract: To meet the demands of cooperative and parallel simulation for multiple unmanned vehicles in simulated battlefield scenarios, and to address the challenges of high data acquisition costs and low simulation efficiency in complex terrestrial environments, this paper develops a neural network-based method for modeling the dynamics of unmanned vehicles. This approach utilizes deep learning and physical embeddings to achieve high-precision nonlinear dynamics simulations. Initially, tire-terrain interaction dynamics models are built using Discrete Element Method (DEM) simulations and experimental data, creating a dataset of tire contact forces for various terrain types such as mud and sand. This dataset is utilized to train a nonlinear neural network tire model suited for complex terrestrial environments. Subsequently, a three-degree-of-freedom dynamics model of the unmanned vehicle incorporating this tire model is constructed, generating a physically meaningful and bounded dataset, which is further used to train a residual neural network for solving vehicle dynamics. The model is validated through its application in

基金项目: 国家自然科学基金(62302517);

第一作者: 王军(1992-), 男, 博士, 研究方向为人工智能, E-mail: wj_xd@foxmail.com

通讯作者: 刘敏(1990-), 男, 博士, 研究方向为人工智能, E-mail: liumin_nudt@163.com

unmanned vehicle trajectory tracking control and its deployment on a domestic supercomputing platform, confirming that the model's computation time is suitable for real-time simulation tasks in military scenarios. The results demonstrate that the neural network-based dynamics solver enables high-accuracy and efficient simulation of unmanned ground vehicles, fulfilling the requirements for vehicle trajectory tracking tasks in simulated battlefield environments.

Keywords: Neural Network; Deep Learning; Automotive Dynamics Modeling; Discrete Element Modeling of Contact; Tire Friction Modeling

0 引言

在常规作战场景的仿真控制领域,车辆运动的建模多基于传统运动学方程。然而,依赖运动学方程的仿真方法存在精度较低和模型难以迁移到真实环境的局限性。特别是在无人驾驶领域,控制策略的无缝迁移从仿真环境到真实环境是一项关键技术,必须依赖于精确的车辆动力学仿真^[1],然而,由于陆域环境下车辆与地面的复杂交互作用,以及动力学特性的非线性与不确定性,高精度车辆动力学计算成为一项难题。此外,基于传统方程的计算方法往往无法满足复杂战场环境下大规模智能体物理解算的实时性要求^[2]。

面向军事领域模拟战场环境下,车辆通常需要在泥地、沙地等软路面工况下运行。这对整车动力学模型提出了更高要求,尤其是轮胎与地面接触动力学的建模,需充分考虑软路面与轮胎间的非线性接触力学特性。然而,目前的大多数研究集中于硬路面条件,对于软路面特性的研究相对较少,其原因在于不同软路面参数差异较大并且轮胎型号多,导致难以通过实验获取丰富数据,从而对轮胎-地面动力学特性进行精确建模。尽管离散元方法 (DEM) 可通过设置土壤参数构建多种软路面条件下的轮胎-地面接触模型,从而获得较为精确的动力学数据,但该方法计算量大、解算速度慢,难以响应战争强对抗条件下的高时效性要求。

针对这一问题,深度神经网络 (DNN) 凭借其强大的表征能力、非线性函数拟合能力以及快速推理能力,展现出在无人车动力学解算中的巨大潜力。通过 DNN 实现的动力学解算,不仅能够显著提升

无人车轨迹跟踪控制的解算速度与数量,还能有效保证复杂战场环境下大规模运动仿真的实时性与准确性。

近年来,众多学者在利用深度学习进行车辆动力学建模方面进行了深入研究。Polack P 等^[3]采用循环神经网络 (RNN) 来近似动力学,证明了任何连续曲线都可以利用 RNN 建模表示。Funahash 等^[4]提出了基于深度神经网络的隐式建模方法,但模型的泛化能力较弱,对训练数据质量和数量高度依赖。Garimella 等^[5]提出了基于 RNN 的无人车动态转向控制模型,实现了采用递归神经网络对自动驾驶汽车的转向动力学进行建模,可以更准确地预测转向动力学。Osman 等^[6]建立了基于全连接神经网络的车辆横向动力学模型,其利用物理模型来确定网络的输入,保证了建模的可靠性。Pan 等^[1]以深度神经网络建模和半递推车辆多体动力学模型为基础,训练和测试了数据驱动模型,并利用商业软件进行了仿真结果对比,验证了网络模型的准确性。Spielberg 和 Rokonuzzaman 等学者基于神经网络的动力学建模与轨迹跟踪控制研究,进一步展示了数据驱动方法对车辆动力学非线性特性的拟合能力^[7-9]。与基于物理机理模型建立动力学模型相比,上述基于纯数据驱动的神经网络建模方法能够较好的拟合出车辆动力学模型非线性特性,但是缺点较为明显:由于忽视了物理规律导致训练得出的模型缺乏解释性,并且其准确性依赖于训练数据集导致模型的泛化能力差。

综上,国内外学者对利用神经网络构建整车动力学模型进行了大量且深入的研究,但在使用中依然存在一些不足:1) 网络模型训练依赖于高质量

的训练数据集, 否则模型效果难以保证; 2) 网络模型学习训练周期长, 收敛效率低; 3) 网络模型泛化能力弱, 缺乏物理边界约束导致模型预测能力差, 预测结果置信度低。

为解决以上问题, 本文提出一种基于虚实结合数据建模的高精度无人车动力学建模方法, 考虑非铺装路面(越野)情况下轮胎-路面之间相互作用, 研究非线性轮胎模型与软路面之间相互作用的特点。首先, 建立具有虚实数据结合的轮胎-路面摩擦内嵌半物理模型, 生成轮胎动力学神经网络模型的训练数据集, 并实现轮胎动力学神经网络模型的学习训练; 然后, 将该模型与无人车动力学模型相结合构建无人车神经网络模型训练数据生成器, 生成包含有物理意义的高质量数据集, 本文提出一种基于虚实结合数据建模的高精度无人车动力学建模方法。最后, 搭建无人车残差神经网络模型, 利用带有物理解释性的数据集进行训练, 形成一种学习效率且具有物理解释性的高精度无人车神经网络模型。

通过仿真验证, 相较于基于物理机理搭建的无人车动力学模型, 基于神经网络搭建的无人车模型解算精度更高, 并且实现了百量级无人车毫秒级的单步解算速度。

1 无人车动力学建模

车辆动力学模型作为车辆运动规律准确推演的基础, 是实现控制算法科学决策的重要依据, 本章将对无人车进行机理分析, 构建包含轮胎动力学模型的三自由度无人车动力学模型, 为后文轮胎动力学神经网络模型及无人车动力学神经网络模型所需训练数据集的构建奠定基础。

如图 1 所示, 本文所涉及模型分别为三自由度无人车动力学模型, 轮胎-路面摩擦内嵌半物理模型, 轮地接触神经网络模型以及嵌入物理知识的无人车动力学神经网络模型。其中轮胎-路面摩擦内嵌半物理模型基于虚实数据结合方法搭建, 其目

的用于快速生成大量具有物理意义的数据集用于学习训练轮地接触动力学的神经网络模型; 所搭建的轮地接触神经网络模型结合无人车动力学模型共同构成无人车神经网络训练数据集生成器, 高效快速的生成具有物理意义及边界的数据集, 用于学习训练无人车动力学神经网络模型, 最终所形成的无人车动力学神经网络模型实现用于各种应用场景下的动力学解算。

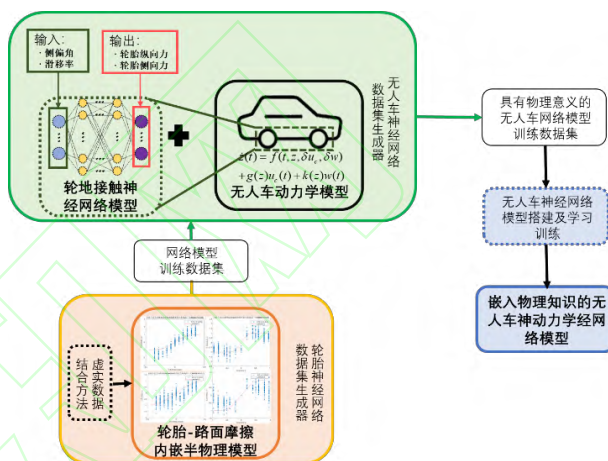


图 1 无人车动力学神经网络搭建流程图

Fig. 1 Flowchart of unmanned vehicle dynamics neural network construction

1.1 无人车轮胎动力学建模

在整车动力学模型当中, 具有强非线性特性的关键部件就是轮胎与路面之间的接触摩擦机理模型, 即轮胎路面接触本构模型。本文考虑非铺装路面(泥地与沙地)情况下从轮胎和路面两个角度对其进行研究分析。

1.1.1 轮胎-非铺装路面接触离散元 (DEM) 建模

该部分利用 EDEM 软件来模拟轮胎-土壤之间的相互作用, 首先选择 Hysteretic-Spring 模型作为离散元中的颗粒模型, 以仿真粘土路面; 然后选择 Hertz-Mindlin(no slip) 模型作为离散元中的颗粒模型, 来仿真沙土路面。之后, 利用所确定土壤离散元颗粒模型参数, 土壤颗粒大小、形状、本征参数、接触参数, 以及土壤与轮胎之间的接触参数, 在

EDEM 中搭建数值单轮土槽模型,沙土和粘土土壤建模参数信息如表 1 所示。




图 2 单轮土槽试验模型

Fig. 2 Single-wheel soil trench test model

表 1 沙土、粘土土壤参数表

Table 1 Table of sand and clay soil parameters


参数名称	沙土颗粒 材料参数	粘土颗粒 材料参数
颗粒形状	球形	球形
颗粒半径(mm)	2	2
颗粒密度(kg/m ³)	2100	1550
剪切模量(MPa)	83	16.5
泊松比	0.25	0.25
颗粒-颗粒恢复系数	0.48	0.58
颗粒-颗粒静摩擦系数	0.51	1.21
颗粒-颗粒动摩擦系数	0.71	0.13
颗粒-几何体恢复系数	0.5	0.48
颗粒-几何体静摩擦系数	0.5	0.55
颗粒-几何体动摩擦系数	0.3	0.37
含水量(%)	15	55
变形模量 n	0.7	0.4
内聚模量 kc(kN/m ⁿ⁺¹)	5.27	16.03
摩擦模量 k _o (kN/m ⁿ⁺¹)	1515.04	126.53
粘聚力 C(kPa)	1.72	2.07
内摩擦角 ϕ (°)	34	10
厚度 mm	300	300

为了实现轮胎运动的精准控制,利用 EDEM 的 Motion Control 功能,分别给轮胎添加绕 y 轴的转速、z 轴的力以及 x 轴的速度,并设定相应方向的运动速度或角速度达到设定值后固定,以此实现对轮胎滚动角速度、行驶速度以及固定滑转率的精准控制。


利用离散元计算轮胎在不同路面上的纵滑与

侧偏工况下的轮胎力,其中纵滑工况考虑在沙地和泥地路面的情况下,轮胎滑移率在 0-1 范围内的特性,侧偏工况同样考虑沙地和泥地路面的情况下,轮胎侧偏角在 -20° ~ 20° 范围内的特性。


通过以上工况仿真,可以获得轮心位移、车轮滑移率(或侧偏角)、沉陷量和挂钩牵引力(驱动力)等结果,继而可以计算得到轮胎在泥地/沙地纵滑牵引力-滑移率之间的关系,即轮胎在泥地/沙地的纵滑特性,应用轮胎的简化物理模型可对该特性数据进行参数辨识,得到对应路面下轮胎的摩擦特性曲线(摩擦系数-滑移速度)。同理也可获得该轮胎在泥地/沙地的侧偏特性,如图 3 所示。




a) 轮胎-沙地侧偏特性分析



b) 轮胎-沙地纵滑特性分析



c) 轮胎-泥地侧偏特性分析



d) 轮胎-泥地纵滑特性分析

图3 轮胎-沙地/泥地纵滑侧偏特性

Fig. 3 Tires - Sand / Mud Longitudinal Slip Side Bias Characteristics

1.1.2 轮胎摩擦本构内嵌半物理建模

由橡胶材料制成的轮胎具有复杂的摩擦本构特性，其摩擦系数是滑移速度的函数，此处建立其 Savkoor 摩擦本构模型如下^[10]：

$$\mu = \mu_0 + (\mu_m - \mu_0) e^{(-h^2 \lg^2 \left| \frac{v_s}{v_m} \right|)}$$

$$v_s = v_x \tan \alpha$$

$$\mu_0 = m_1 e^{\frac{-F_m}{m_2}}$$

$$\mu_m \approx m_3 e^{\frac{-F_m}{m_4}}$$

$$h = h_1 e^{\frac{-F_m}{h_2}}$$

$$v_m = v_{m1} + v_{m2} F_{zn} + v_{m3} F_{zn}^2$$

式中 v_s 为滑移速度，其表达式为 $v_s = v_x \tan \alpha$ ， v_x 为轮胎滚动速度； μ_0 、 μ_m 、 h 、 v_m 分别为与载荷相关的模型参数，其表达式分别为： $\mu_0 = m_1 e^{\frac{-F_m}{m_2}}$ ， $\mu_m = m_3 e^{\frac{-F_m}{m_4}}$ ， $h = h_1 e^{\frac{-F_m}{h_2}}$ ， $v_m = v_{m1} + v_{m2} F_{zn} + v_{m3} F_{zn}^2$ ，其中， m_1 、 m_2 、 m_3 、 m_4 、 h_1 、 h_2 、 v_{m1} 、 v_{m2} 、 v_{m3} 等参数均由数据拟合而得。

结合上述离散元仿真模型，进行不同垂向载荷和滑移速度的仿真，产生了多载荷工况下的数据，如图 4data 数据所示，从图 4 中可以看出，统一滑移速度下有多个数据点，分别代表了不同的垂向载荷。经过数据拟合，得出沙地、泥地路面 Savkoor 摩擦本构模型拟合结果如图 4 图 5 中红线所示：

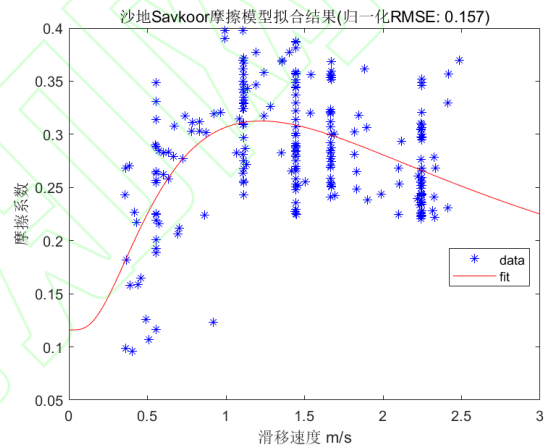


图4 沙地路面 Savkoor 摩擦本构模型拟合结果

Fig. 4 Fitting results of Savkoor friction principal model for sand pavements

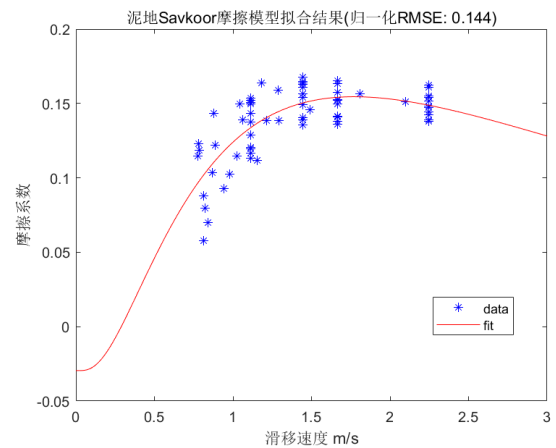


图5 泥地路面 Savkoor 摩擦本构模型拟合结果

Fig. 5 Fitting results of Savkoor friction principal model for Mud pavements

面对在模拟战场环境中存在多材质路面,且存在无人车智能体轮胎型号多、工况多、并行计算模型数量多等问题,提出无人车轮胎物理建模的归一化方法,实现陆域环境下多无人车智能体轮胎力学解算的型号间、工况间的相互预测和统一建模。轮胎建模的无量纲思想分别定义无量纲滑移率(统一纵滑滑移率和侧偏滑移率)和无量纲切向力(无量纲纵滑力和无量纲侧偏力),经理论推导和大量轮胎试验数据统计验证,不同型号轮胎和同型号不同载荷轮胎侧偏和纵滑特性经无量纲处理后具有高度近似性,这为不同型号轮胎和不同载荷轮胎之间的力学特性和力学解算的相互预测提供了理论依据。如图 6 所示,依据硬路面轮胎实验获取不同载荷下的轮胎切向力实现轮胎无量纲建模,依据橡胶块摩擦实验获取不同摩擦系数下的摩擦力,实现轮胎摩擦本构方程的建立,二者相结合即为归一化技术的不同型号轮胎力学特性的相互预测方法,该方法可以实现不同轮胎型号和不同载荷条件下轮胎力的无量纲建模方法,结合仿真数据即可实现不同轮胎动力学模型的建模。

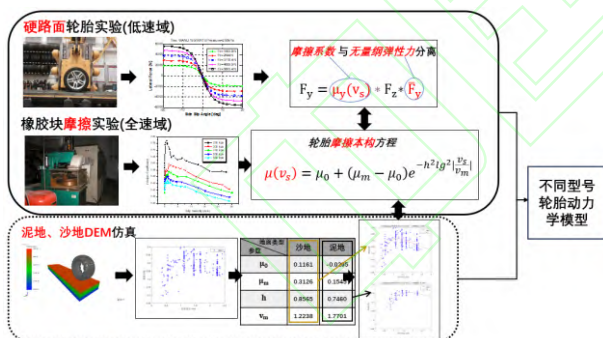
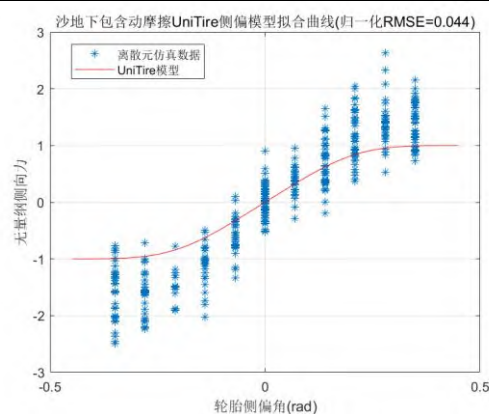


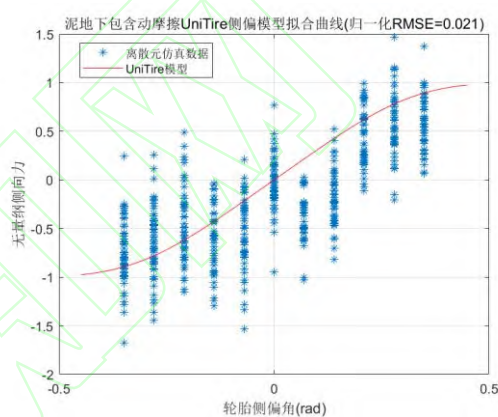
图 6 基于归一化技术的不同型号轮胎力学特性的相互预测图

Fig. 6 Mutual prediction diagram of mechanical properties of different tire models based on normalization technology

结合上述归一化技术的不同型号轮胎力学特性的相互预测方法,将考虑滑移速度的摩擦本构模型加入上述的 UniTire 模型,建立包含动摩擦的无量纲轮胎模型,拟合结果如图 7、图 8 所示。

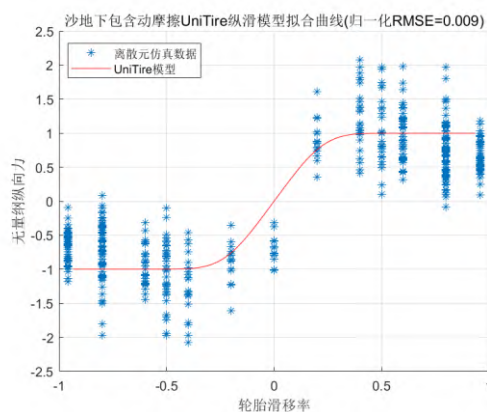


a) 沙地路面轮胎侧偏力拟合结果




b) 泥地路面轮胎侧偏力拟合结果

图 7 沙地、泥地路面轮胎侧偏力拟合结果
Fig. 7 Fitting results of tire side deflection force on sand/mud road surface



a) 沙地路面轮胎纵滑力拟合结果



b) 泥地路面轮胎纵滑力拟合结果

图 8 沙地、泥地路面轮胎纵滑力拟合结果

Fig. 8 Fitting results of tire side longitudinal slip force on sand/mud road surface

图 7、图 8 为某一规格轮胎基于归一化技术的不同型号轮胎力学特性的相互预测技术所建立的轮胎-地面接触动力学模型，为了验证所建模型的有效性以及图 6 提出方法的正确性，采用不同规格的实际的车辆轮胎进行试验验证，对其进行了载荷在 5170N、3390N、2000N 工况下的测试，其中纵滑模型试验的滑移率范围为-0.3~0.3，侧偏模型试验的侧偏角范围为-16°~16°。试验数据结果与仿真模型对比结果图 9、图 10 所示，通过对比发现其误差均方根值非常小，证明所建立的模型是有效的。

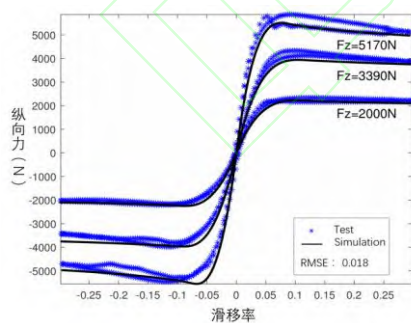


图 9 纵滑模型试验与仿真对比

Fig. 9 Comparison of experimental and simulated longitudinal slip models




图 10 侧偏模型试验与仿真对比

Fig. 10 Comparison of Side Deviation Model Experiments and Simulations

1.2 三自由度无人车动力学建模

为了更好的表述整车的操纵性，在二自由度整车模型的基础上，考虑纵向车速 V_x 的变化，建立三自由度单轨汽车模型。虽然三自由度单轨汽车模型较简单，但其基本可以描述本文无人车模型的操纵特性，同时也将为研究更复杂的无人车模型打下坚实的理论基础^[11]。三自由度单轨汽车模型如图 11 所示。




图 11 三自由度单轨汽车模型及车轮动力学模型

Fig. 11 Three degree of freedom monorail vehicle model and wheel dynamics model

三自由度单轨汽车模型包含了沿着 x 轴的纵向运动、沿着 y 轴的侧向运动以及绕 z 轴的横摆运动，坐标系采用体坐标系。车辆沿 x 、 y 轴的纵、侧向力平衡方程以及绕 z 轴的力矩平衡方程分别如下所示。

$$\begin{aligned}\dot{V}_x &= \frac{F_x - F_{xr} \cdot \sin(\delta)}{m} + \gamma \cdot V_y \\ \dot{V}_y &= \frac{F_{xr} \cdot \cos(\delta) + F_y}{m} - \gamma \cdot V_x \\ \dot{\gamma} &= \frac{aF_{xr} \cdot \cos(\delta) - bF_{xr}}{I_z}\end{aligned}$$

其中, F_{xr} 、 F_{yf} 、 F_{yr} 分别表示前后轮侧向力; m 表示整车质量; V_x 表示整车质心处的纵向速度, 在此处作为模型中的一个参数; V_y 为整车质心处的侧向车速; γ 表示绕 z 轴的横摆角速度; β 表示质心侧偏角; δ 表示前轮转角; a 、 b 表示质心至前后轴的距离; I_z 表示整车转动惯量。

根据质心侧偏角定义, 有 $V_y = V_x \tan(\beta)$, 因此有:

$$\dot{V}_y = \dot{V}_x \tan(\beta) + V_x \cdot \frac{1}{\cos^2(\beta)} \dot{\beta}$$

可得由质心侧偏角、横摆角速度、纵向车速作为状态变量的整车模型, 其表达式:

$$\begin{aligned}\dot{\beta} &= \left[\frac{F_{yf} \cdot \cos(\delta) + F_{yr} - (F_{xr} - F_{yf} \cdot \sin(\delta)) \cdot \tan(\beta)}{m \cdot V_x} \right] \\ &\quad \cdot \cos^2(\beta) - \gamma \\ \dot{\gamma} &= \frac{aF_{yf} \cdot \cos(\delta) - bF_{yr}}{I_z} \\ \dot{V}_x &= \frac{F_{xr} - F_{yf} \cdot \sin(\delta)}{m} + \gamma \cdot V_x \cdot \tan(\beta)\end{aligned}$$

地面对车轮的纵向力表现为车轮坐标系内的力 F_x , 驱动系统对车轮的作用力被简化为轮心处力矩 T 。

当外力已知的情况下, 根据牛顿-欧拉方法列写车轮的动力学方程:

$$I_z \dot{\omega} = T - F_x R_w$$

ω 为车轮的角速度, R_w 为车轮滚动半径, I_z 为车辆转动惯量。

2 无人车动力学神经网络设计与训练

2.1 训练数据

2.1.1 基于虚实结合的轮胎动力学神经网络训练数据生成

针对在软路面条件下无人车关键动力学特性试验获取成本高和仿真获取计算效率低的问题, 本文提出无人车轮胎虚实结合的神经网络训练数据集生成方法, 具体流程如图 12 所示。

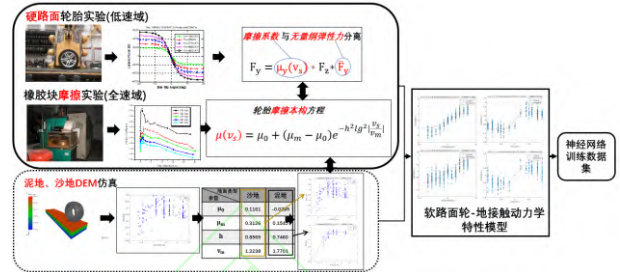


图 12 虚实结合数据神经网络数据集生成流程图
Fig. 12 Flowchart of neural network dataset generation for real and virtual data

通过轮胎侧偏、纵滑台架试验、橡胶摩擦试验以及不同材质路面轮胎虚拟侧偏、纵滑试验结合软路面(泥地、沙地) DEM 离散元仿真实现虚实结合, 构建能够反应软路面特性的轮胎-地面接触动力学模型。虚实结合体现在利用离散元仿真数据形成的结合 Savkoor 摩擦模型建模方法, 探究轮地接触摩擦力学中的动摩擦因数 $\mu(v_x)$ 及其相关参数 μ_m 、 μ_0 、 h 、 v_m , 结合低速域及全速域情况下的试验生成的数据, 基于摩擦系数与无量纲弹性力分离技术, 共同构建能够反应软路面特性的轮胎-地面接触动力学模型, 形成一种虚实数据融合方法, 经过试验验证, 基于虚实数据融合方法构建的模型所形成的数据与通过试验所形成的数据误差极小, 具体对比如图 9、图 10 所示。基于上述方法, 可进行大批量多种路面仿真模拟, 形成具有物理意义的数据集, 为后续建立反映各种路面的轮胎动力学神经网络模型奠定了基础。

2.1.2 三自由度无人车神经网络训练数据生成

基于文章上述内容建立的无人车动力学理论模型之后需要通过数值计算方法, 编写数值求解代码, 其中比较重要的就是数值积分求解器, 由解析的微分方程通过数值方法求解。数值积分求解器是

物理解算的核心组成部分,推动车辆的运动状态从当前时刻运行到下一仿真时刻。当前,已经有多种成熟的数值积分算法,对算法的选择应该根据建模的对象,求解的问题和应用的领域来综合考虑,并不是误差越小,求解越精确就是适用的算法,在选择算法时需考虑:

1. 在整个时间区域上,均能计算得到满足用户精度要求的数值解,并且计算所需的时间足够短;
2. 面向车辆动力学的应用需求,实时动力学系统常采用定步长的积分求解算法;
3. 隐式算法会降低仿真的求解效率,不能很好满足硬件在环仿真的要求,因此面向车辆动力学的应用需求采取显式算法;

基于上述考虑,选用定步长—二阶—显式积分算法,使用的积分方法为 ADAMS-BASHFORTH 线性多步法,这种积分算法已为密西根十七自由度模型和吉林大学汽车性能模拟器二十九自由度模型所采用,经验证其计算较为准确并且十分稳定。具体计算公式如下:

$$y_{n+1} = y_n + \frac{h}{2}(3f_n - f_{n-1})$$

相应的局部截断误差为:

$$T_{n+1} = \frac{5}{12}h^3 y'''(\eta_n)$$

基于本文上述搭建的无人车动力学模型以及选择的数值求解方法,对陆域物理环境作用下的无人车运动进行高精度数值仿真及结果分析,实现对多工况的无人车运动进行高精度模拟仿真,包括多种车辆常规机动动作(前进,后退,转向等),形成可用于训练具有物理意义的神经网络的高质量数据集,主要流程如图 13 所示。

其中上层控制器以生成多工况(速度不同、轨迹不同)下车辆数据集为目标,向图中搭建的无人车动力学模型发送转矩、转向等指令信息,无人车动力学模型依据指令信息解算得到下一时刻的状态信息并反馈回上层控制器,上层控制器基于反馈

信息生成神经网络训练数据集。

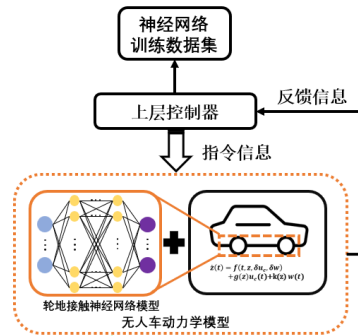


图 13 神经网络模型数据集生成流程图

Fig. 13 Neural network model dataset generation flowchart

2.2 无人车神经网络结构

神经网络作为深度学习的重要组成部分,是通过模仿人脑神经元而来的^[12],如图 11 所示,神经网络模型的最大特点是含有多层隐藏层^[13],其已在机器人控制、汽车自动驾驶、轨迹跟踪以及信息检索等多个领域中成功应用^[14-16]。

虽然神经网络能够较好地拟合非线性模型,但随着其网络层数的增加,深度较大的神经网络会出现退化现象^[17],并且随着深度的增加,会出现梯度消失/梯度爆炸等问题。

为了解决以上问题,本文采用残差神经网络(Residual Neural Network)结构,基本结构如图 14 所示,残差神经网络的主要设计思想是快捷链接和恒等映射,其中快捷连接使残差变得可能,恒等映射可以允许神经网络的深度被设计的更深^[17]。




图 14 残差神经网络基本架构

Fig. 14 Basic Architecture of Residual Neural Network

本文依据残差神经网络理论结构构建无人车残差网络学习模型,对包含有非线性轮地接触动力

学模型的三自由度无人车动力学模型进行状态量预测。无人车下一时刻的状态量为网络模型的输出，无人车的前轮转角、驱动力矩，结合上一时刻的无人车状态量作为网络模型的输入，如图 15 所示。

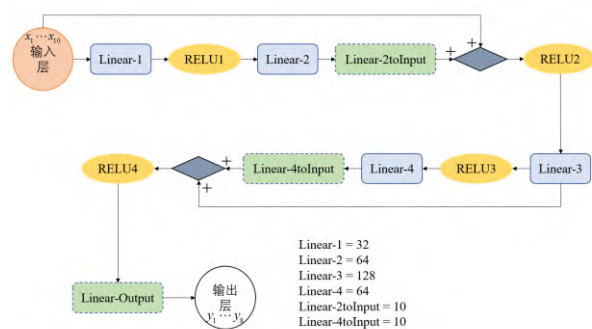


图 15 无人车残差网络模型

Fig. 15 Residual Network modeling of Unmanned Vehicle

如图 15 所示，无人车残差网络模型采用了 6 个线性（隐藏）层，理论上可以更深，每个线性层数分别为 32、64、128、64、10、10，并且输入层的 x_1 - x_{10} 为上述无人车上一时刻 8 项状态量：航向角、质心侧偏角、横摆角速度、质心侧偏角角速度、纵向速度、侧向速度、纵向加速度、侧向加速度以及 2 项无人车控制量：前轮转角、驱动力矩；输出层的 y_1 - y_8 为无人车下一时刻 8 项状态量。

2.3 无人车神经网络训练

试验硬件环境：CPU 为：Intel(R) Core(TM) i7-13700KF，GPU 为 Nvidia GeForce RTX 4070Ti，计算机操作系统为 Windows 11，内存为 32 GB。采用训练框架为 TensorFlow，训练样本数 500 000；批量数 Batch Size 为 256；学习率为 0.001；优化器为 Adam；激活函数：ReLU，Loss 函数为 MSELoss，总训练轮数 epoch 为 20，模型初始化参数为随即参数。

前向传播和反向传播作为神经网络学习训练过程中最关键的环节^[18]。在前向传播环节，各个神经元的权值和偏置值得到初始化设置，并在传播过程结束后利用得到的输出值计算损失函数 Loss 数值；反向传播环节则是利用 Loss 以及梯度下降法

对各个神经元间的权值和偏置值进行更新。海量的训练数据在前向传播环节和反向传播环节中反复进行，并以 Loss 曲线作为判断网络学习模型训练效果的重要指标，通过损失函数随训练迭代步数的变化直观的评估模型在训练过程中的优化情况。

如图 16 所示，本文所提出的具有物理可解释性的无人车残差神经网络模型能够训练到收敛状态，Loss 下降速度较快，表明本文所建立的残差神经网络模型能够在较少的样本数及较短周期的情况下快速的学习到本文所提出的结合有轮胎非线性动力学模型的无人车动力学模型的特征；Loss 值收敛到 10^{-6} 级别表明训练完成的模型已经取得了较高的精度。




图 16 无人车残差神经网络模型训练过程 Loss 曲线

Fig. 16 Loss curves for the training process of residual neural network models for unmanned vehicles

3 结果分析及仿真验证

3.1 神经网络模型验证方法


为了验证本文所提出的具有物理可解释性的无人车残差神经网络学习模型的训练效果,给定随机车况下无人车的行驶状态以及控制,预测车辆下一时刻的行驶状态。

本文研究的无人车行驶状态后续将用于轨迹跟踪控制,无人车运行状态更加侧重于横摆角速度、纵向速度、侧向速度、纵向加速度、侧向加速度五项汽车行驶状态,因此本文将验证预测结果与实际结果之间的接近程度,来进一步验证学习模型效果的好坏情况。

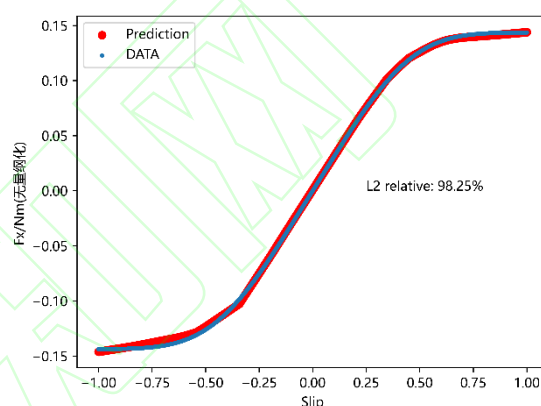
为了更准确验证学习模型效果的好坏,除了直观法画出实际值与预测值对比曲线,还分别采用采用决定系数 R^2 (Coefficient of Determination)^[19]和 Pearson 相关系数法^[20, 21]。其中,决定系数 R^2 分数作为评估学习模型的重要指标,用于衡量模型对目标变量的解释能力,其取值范围在 0 到 1 之间,越接近 1 表示模型对目标变量的变异性解释得越好,即学习模型训练效果越好; Pearson 相关系数则是评估实际值与预测值之间的线性关系,相关系数接近 1 表示强正相关,接近-1 表示强负相关,而接近 0 表示无线性关系。

3.2 轮胎神经网络模型结果

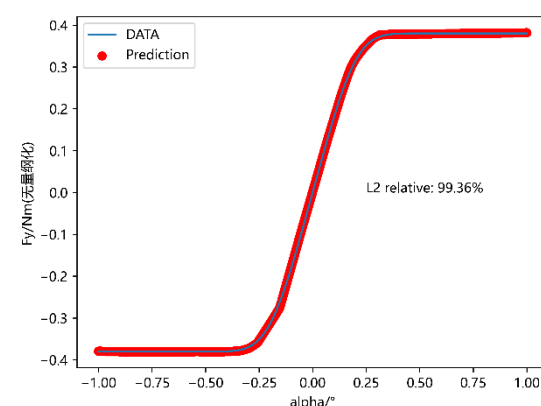
轮胎神经网络模型基于前馈全连接神经网络搭建,输入分别为侧偏角和滑移率;输出分别为:纵向力和侧向力,模型训练结果如图 17 所示,观察图中结果可以得出轮胎神经网络模型预测值与实际值几乎重合,所搭建的轮胎神经网络模型训练效果理想,并且所搭建的轮胎神经网络模型既能表征泥地环境下轮胎的动力学特征,又可以表征沙地环境下轮胎的动力学特征,具有较强的鲁棒性及泛化能力。




a) 泥地环境下侧偏特性训练验证结果



b) 泥地环境下纵滑特性训练验证结果




c) 沙地环境下侧偏特性训练验证结果




d) 沙地环境下纵滑特性训练验证结果

图 17 非线性神经网络轮胎模型训练验证结果

Fig. 17 Nonlinear neural network tire model training and validation results



d) 无人车纵向加速度




e) 无人车侧向加速度

图 18 样本数据对比测试结果


Fig. 18 Sample Data Comparison Test Results

3.3 无人车神经网络模型训练结果


在学习模型训练完成后,采用全新的验证集共 30000 条样本进行验证,以无人车的横摆角速度、纵向速度、侧向速度、纵向加速度、侧向加速度五项行驶状态为目标,并分别计算了其 Pearson 相关系数和决定系数 R^2 分数,结果如下图所示:



a) 无人车横摆角速度



b) 无人车纵向速度



c) 无人车侧向速度

如图 18 所示,直观法观察到无人车的横摆角速度、纵向速度、侧向速度、纵向加速度、侧向加速度五项行驶状态的实际值与预测值高度重合,从决定系数 R^2 和 Pearson 相关系数的值均(大于 0.9999)接近于 1,得证具有比物理可解释性的无人车残差神经网络模型训练效果理想。

为了实现更好地对比,本文分别基于前馈网络(FNN)构型和循环神经网络(RNN)构型建立了前馈神经网络模型和循环神经网络模型,在相同的学习训练条件下,利用相关性系数作为评判标准,对比验证各个神经网络的学习训练效果,对比结果如下表所示。综合下表可以得出,前馈神经网络对于纵向车速的表达较差,循环神经网络对于纵向加速度以及纵向速度的表达较差,而残差神经网络模型对于各状态量均能实现较好的预测表达。

表 2 各神经网络构型验证结果对比
Table 2 Comparison Table of Configuration Verification Results of Various Neural Networks

输出状态量	残差神经网络	前馈神经网络	循环神经网络
横摆角速度	0.999998	0.998507	0.841569
纵向速度	0.999978	0.512992	0.187719
侧向速度	0.999991	0.998709	0.706560
纵向加速度	0.999991	0.996608	0.177136
侧向加速度	0.999998	0.999840	0.925140

经过搭建、学习训练并利用验证集完成验证的具有物理可解释性的无人车神经网络模型,结合轨迹跟踪控制算法形成的轨迹跟踪控制器,对比同一轨迹跟踪控制算法下物理机理模型的轨迹跟踪效果和神经网络模型轨迹跟踪效果,对比结果如图 19 所示。






图 19 神经网络模型与物理机理模型轨迹跟踪效果对比图
Fig. 19 Comparison of the effect of trajectory tracking based on the neural network model and the physical mechanism model

如图 19 所示,红色曲线代表目标轨迹,蓝色线代表神经网络模型轨迹跟踪路线,橘色线为物理机理模型轨迹跟踪路线,通过对比发现,二者均能完成目标轨迹跟踪,但是在无人车进行转向控制时,基于神经网络模型的无人车动力学模型相较于物理机理模型的无人车动力学模型能够较快的做出转向反应,并且产生的波动更小,且行驶路线与目标轨迹重合度更高,因此可以证明:相较于传统机理建模方法,基于神经网络模型的建立的无人车动力学模型精度更高且可控性更换好,能够更好的完成既定轨迹的跟踪控制,可以应用于战场、物流等多种场景。

为验证在极限条件下如泥地沙地下的解算精度,在泥地和沙地环境下进行开环控制仿真,分别与基于物理机理模型解算对比,结果如图 20 所示,相关性技术接近大于 99%证明该模型解算精度高,能够应用极限条件下控制需求。



a) 沙地环境开环控制仿真



b) 泥地环境开环控制仿真

图 20 极限工况开环控制仿真效果

Fig. 20 Extreme condition open-loop control simulation results

将上述解算模型部署于天河计算机超算平台,经测验,其单步解算时长为 0.006s,具备较快的结算速度,满足模拟战场情景下无人车仿真物理解算模型的实时性要求,能够完成多无人车辆间的协作及高时效并行计算仿真。

4 结论

本文基于虚实结合数据建模方法,研究非线性轮胎-路面之间相互作用,建立了结合轮胎-路面摩擦内嵌半物理模型,构建了具有高精度解算的陆域复杂环境适用的非线性神经网络轮胎模型,学习训练效果较好。结合无人车动力学模型,构建了包含轮胎特性神经网络与整车动力学物理模型的无人车动力学模型,并以此作为无人车神经网络模型训练数据集的生成器,可以高效的生成用于训练无人车神经网络模型的训练数据集。

本文搭建了无人车神经网络模型,并且基于上述训练数据集,神经网络模型学习训练效果较好,可以实现高效的无人车动力学解算。通过轨迹跟踪控制仿真验证方法,验证了与基于物理建模的无人车动力学模型相比,基于神经网络建模的无人车动力学模型精度更高、可控性更好。基于开环仿真控

制仿真验证方法,验证了该模型能够应用于极限条件下的无人车控制。所构建的无人车神经网络模型可以实现陆域无人车动力学仿真的高精度、高效率,保证解算的实时性,并且实现了在天河超算平台的部署验证。

参考文献

- [1] Pan Y, Nie X, Li Z, et al. Data-driven vehicle modeling of longitudinal dynamics based on a multibody model and deep neural networks[J]. 2021, 180: 109541-.
- [2] Liu X W, Ning J Nonlinear Dynamics. Uncertainty observation-based adaptive succinct fuzzy-neuro dynamic surface control for trajectory tracking of fully actuated underwater vehicle system with input saturation[J]. 2019, 98(3).
- [3] Funahashi K I, Nakamura Y J N N. Approximation of dynamical systems by continuous time recurrent neural networks[J]. 1993, 6(6): 801-6.
- [4] Devineau G, Polack P, Altché F, et al. Coupled Longitudinal and Lateral Control of a Vehicle using Deep Learning[J].
- [5] Garimella G, Funke J, Wang C, et al. Neural network modeling for steering control of an autonomous vehicle; proceedings of the Intelligent Robots and Systems, F, 2017 [C].
- [6] Osman O A, Rakha H J T R R J O T T R B. Application of Deep Learning for Characterization of Drivers' Engagement in Secondary Tasks in In-Vehicle Systems[J]. 2020, 2674(1): 036119812092650.
- [7] Spielberg N A, Brown M, Kapania N R, et al. Neural network vehicle models for high-performance automated driving[J]. Science Robotics, 2019, 4(28): eaaw1975.
- [8] Spielberg N A, Brown M, Gerdes J C. Neural network model predictive motion control applied to automated driving with unknown friction[J]. IEEE Transactions on Control Systems Technology, 2021, 30(5): 1934-45.
- [9] Rokonzaman M, Mohajer N, Nahavandi S, et al. Model Predictive Control With Learned Vehicle Dynamics for Autonomous Vehicle Path Tracking[J]. IEEE Access, 2021.
- [10] 庄晔. 轮胎动摩擦特性研究及其对车辆操纵稳定性的影响[D]; 吉林大学, 2004.
Zhuang Ye. Study on the dynamic friction characteristics of tyres and its effect on the stability of vehicle handling [D]. Jilin University, 2004.
- [11] 李翔宇, 么鸣涛, 李宝玉, 等. 基于 MATLAB 的汽车操纵稳定性仿真分析. 汽车实用技术[J]. 2023, 48(24): 95-100.
Li Xiangyu, Miao Mingtao, Li Baoyu et al. Simulation analysis of vehicle handling stability based on MATLAB[J]. Automotive Practical Technology, 2023, 48(24): 95-100. DOI:10.16638/j.cnki.1671-7988.2023.024.019
- [12] Yann, Lecun, Yoshua, et al. Deep learning[J]. 2015.
- [13] 柴慧敏, 张勇, 李欣粤, 等. 基于深度学习的空中目标威胁评估方法[J]. 2022, 34(7): 9.
CHAI Huimin, ZHANG Yong, LI Xinyue, et al. Deep learning-based threat assessment method for airborne targets[J]. Journal of System Simulation, 2022, 34(7): 9.
- [14] 孙辉辉, 胡春鹤, 控制与决策 张军国. 移动机器人运动规划中的深度强化学习方法[J]. 2021, 36(6): 12.
SUN Huihui, HU Chunhe, ZHANG Junguo. Deep reinforcement learning approach in motion planning for mobile robots[J]. Control and Decision Making, 2021, 36(6): 12. doi:10.13195/j.kzyjc.2020.0470.
- [15] 杨路辉, 刘光杰, 翟江涛, 等. 一种改进的卷积神经网络恶意域名检测算法[J]. 2020, (1): 37-43.
YANG Luhui, LIU Guangjie, ZHAI Jiangtao, et al. An improved convolutional neural network malicious domain name detection algorithm[J]. Journal of Xi'an Electronic Science and Technology University, 2020(1): 37-43.
- [16] 胡琦瑶, 杨皓文, 王佳欣, 等. 基于弱监督深度学习的图像检索技术研究[J]. 2020, 50(5): 9.
HU Qiyao, YANG Haowen, WANG Jiaxin, et al. Research on image retrieval techniques based on weakly supervised deep learning[J]. Journal of Northwestern University: natural science edition, 2020, 50(5): 9. DOI:10.16152/j.cnki.xdxzbzr.2020-05-013.
- [17] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. 2016.
- [18] 全卫国, 曾世超, 张立峰, 等. 基于深度残差神经网络的电阻层析成像及流型辨识方法[J]. 2022, 34(9): 9.
Tong Weiguo, Zeng Shichao, Zhang Lifeng, et al. Resistive laminar imaging and flow pattern identification method based on deep residual neural network[J]. Journal of System Simulation, 2022, 34(9): 9. DOI:10.16182/j.issn1004731x.joss.21-0294.
- [19] 胥雪炎, 太原科技大学学报 李 补喜. 不同被解释变量选择对决定系数 R^2 的影响研究[J]. 2007, 28(5): 3.
XU Xueyan, LI Tuanxi. A study on the effect of different choices of explanatory variables on the coefficient of determination R^2 [J]. Journal of Taiyuan University of Science and Technology, 2007, 28(5): 3. DOI:10.3969/j.issn.1673-2057.2007.05.013.
- [20] 柴同, 袁逸萍, 马军岩, 等. 基于 K-CNN 和 N-GRU 的风电机组发电机状态预测[J]. 2023, 45(5): 1043-9.
CHAI Tong, YUAN Yiping, MA Junyan, et al. Generator state prediction for wind turbines based on K-CNN and N-GRU[J]. Mechanical Strength, 2023, 45(5): 1043-1049.
- [21] Wool, Daniels H E J B. THE RELATION BETWEEN MEASURES OF CORRELATION IN THE UNIVERSE OF SAMPLE PERMUTATIONS[J]. 1944, 33(2): 129-35.